

İskemik İnme Lezyonlarının Gerçek Zamanlı Segmentasyonu

0. Çalışma nasıl ilerledi

Bu bölüm çalışmanın kısa anlatımı. Her adımda ne yaptığımı, neden öyle yaptığımı, ne çıktığını ve ne öğrendiğimi sırayla aktarıyor. Kısa sonuç şu. Kalite tarafında denenen hiçbir şey en basit modeli geçemedi. Hız tarafında ise kazanç modelden değil ön işlemeden geldi ve vaka başına 138 milisaniyelik bir hat elde edildi. Sayıların nasıl ölçüldüğü ve istatistiksel karşılaştırmalar sonraki bölümlerde.

Önce veriye baktım

İlk iş 250 vakanın dağılımlarını çıkarmak oldu. Bunu eğitime başlamadan önce yaptım, çünkü veri setinin kendisi hangi kararların alınabileceğini belirliyor. Dört şey çıktı. Voxel boyutu vakadan vakaya değişiyordu, ADC üç farklı ölçekte geliyordu, lezyon hacmi aşırı çarpıktı ve vakaların dörtte üçü çok odaklıydı. İlk ikisi düzeltilmeseydi model ADC kanalını kullanamazdı. Son ikisi ise sonuçların tek bir ortalama Dice ile verilemeyeceğini baştan gösterdi. Öğrendiğim şey basit. Yarım günlük keşif, sonradan fark edilseydi bütün koşulları çöpe atacak iki hatayı önledi.

Sonra dokuz model eğittim

Beş mimari ve dört ablasyon eğittim. Hepsinde veri bölünmesi, augmentasyon, optimizasyon ve epoch bütçesi sabit kaldı, çünkü değişen tek şeyin mimari olması gerekiyordu. Sonuç beklediğim gibi çıkmadı. Dokuz koşunun tamamı 0,64 ile 0,70 arasında toplandı ve hiçbirisi en basit modeli, yani 2B U-Net taban çizgisini geçemedi. Transformer encoder, hafif encoder ve FLAIR eklemek işleri kötüleştirdi. Buradan çıkardığım şu. Bu görevde mimari seçimi düşündüğüm kadar belirleyici değil, ve negatif sonuç da bir sonuç.

Farkların gerçek olup olmadığını sınıadım

Sıralamanın en üstüne bakıp 3B U-Net en iyisi demek kolaydı. Bunu yapmadım, çünkü farklar küçüktü ve ölçüm gürültüsünün ne kadar olduğunu bilmiyordum. Aynı mimarinin üç varyantı 0,024 genişliğinde bir banda yayılıyordu, yani modeller arası farkların çoğu bu bandın içinde kalıyordu. Eşleştirilmiş testlerden sonra yalnızca üç modelin taban çizgisinden ayrıştığı görüldü ve üçü de kötü yöndeydi. Öğrendiğim şey, sıralama tablosunun tek başına bir şey söylemediği. Önce gürültüyü ölçmek gerekiyor.

Sonra hattı hızlandırdım

Gerçek zamanlılık için önce zamanın nereye gittiğini ölçtüm. Optimizasyon planım tamamen modeli hedefliyordu, ama ölçüm sürenin dörtte üçünün ön işlemeye gittiğini gösterdi. Bu yüzden planı değiştirip yeniden örneklemeyi ve beyin maskesini GPU'ya taşıdım. Vaka başına süre 385 milisaniyeden 138 milisaniyeye indi. ONNX ve TensorRT ise izole ölçümde hızlı görünmelerine rağmen gerçek hatta hiçbir kazanç vermedi ve yığından çıkarıldı. Buradaki ders en pahalı olanı. Ölçmeden optimize etmeye başlasaydım, bütün emeği yanlış yere harcayacaktım.

En sonunda servise bağladım

Modeli, ham dosyaları alıp lezyon maskesi, hacim, lezyon sayısı ve hemisfer bilgisi döndüren bir servise dönüştürdüm. Servis ayrıca vaka başına okunabilir bir rapor üretiyor. Burada ölçtüğüm şey ilk isteğin süresiydi. Isıtma yapılmadığında ilk istek 331 milisaniye sürüyordu, yani kararlı halin üç katı. Açılışta sentetik

bir hacmi tüm hattan geçirince bu süre 85 milisaniyeye indi. Öğrendiğim şey, çalışan bir modelle çalışan bir servisin aynı şey olmadığı.

1. Amaç, veri ve protokol


Akut iskemik inmede tıkalı damarın beslediği doku dakikalar içinde kayboluyor. Tedavi kararı büyük ölçüde geri döndürülemez biçimde ölmüş çekirdek bölgenin büyüklüğüne dayanıyor. Bu hacim büyüdükçe damar açma girişiminin beklenen faydası azalıyor ve kanama riski artıyor. Dolayısıyla hacim ölçümünün hem hızlı hem de tekrarlanabilir olması gerekiyor. Elle çizim ikisini de sağlamıyor, çünkü vaka başına dakikalar sürüyor ve gözlemciden gözlemciye değişiyor. Difüzyon ağırlıklı MR bu ölçümün ana dizisi, çünkü infarkt çekirdeği ilk dakikalardan itibaren belirgin sinyal veriyor. Gerçek zamanlılık hedefi de buradan geliyor. Ölçüm, klinik kararın önüne geçmeyecek kadar kısa sürmek zorunda.

Hedef, difüzyon ağırlıklı MR üzerinde akut ve subakut infarkt lezyonunun gerçek zamanlı segmentasyonu. Çalışma iki soru soruyor. Hangi mimari daha iyi segmentliyor, ve hangi hat klinik akışta kabul edilebilir bir sürede çalışıyor. Veri kaynağı ISLES 2022 (Ischemic Stroke Lesion Segmentation Challenge 2022) eğitim kümesi. Küme 250 vakadan oluşuyor ve her vakada DWI ($b=1000$), ADC ve FLAIR serileri ile uzman çizimli ikili lezyon maskesi bulunuyor. Challenge'ın 150 vakalık test kümesi yayınlanmadı. Bu nedenle değerlendirme, 250 vaka içinde vaka düzeyinde ayrılan bir test kümesiyle yapıldı.

Veri setinin taşıdığı bilgi çalışmanın kapsamını da belirliyor. Küme yalnızca MR içeriyor ve NCCT serisi barındırmıyor, dolayısıyla çalışma difüzyon MR üzerinde kurgulandı. NCCT taşıyan ikinci bir veri seti eklemek değerlendirildi ama kapsam dışında bırakıldı. Tek bir modalite üzerinde derinlemesine karşılaştırma yapmak tercih edildi. Perfüzyon serisi de bulunmadığından core ve penumbra ayrımı üretilmiyor ve çıktı tek bir infarkt maskesi. Bu ayrım klinikte reperfüzyon kararının dayandığı büyüklük. Sınırlılık olarak kayda geçiyor ve raporun sonunda tekrar ele alınıyor.

1.1 Veri keşfi ve alınan kararlar


250 vakanın tamamında dört serinin dördü de mevcut. Ölçümler dört karar doğurdu.



Şekil 1. Veri setinin dağılımları. Sırasıyla lezyon hacmi, vaka başına bağlı lezyon sayısı, lezyon voxel oranı, lezyonsuz dilim oranı, merkeze göre hacim ve DWI voxel aralıkları. Hacim dağılımının çarpıklığı ve çok odaklılığın yaygınlığı, sonuçların tek bir ortalamayla verilemeyeceğini gösteriyor.

Voxel boyutu tek değil. DWI ve ADC serilerinde on yedi farklı matris boyutu ve yedi farklı voxel aralığı var. 193 vaka $2 \times 2 \times 2$ mm izotropik, buna karşılık 52 vaka 4,8 mm dilim kalınlığında. Ortak bir grid olmadan ne hacim karşılaştırılabilir ne de komşu dilim bağlamı anlamlı olur. Beş dilim bir vakada 10 mm'ye, diğerinde 24 mm'ye karşılık gelir. Bütün hacimler $2 \times 2 \times 2$ mm'ye yeniden örneklendi. Çoğunluk zaten orada olduğu için bu, veriye en az müdahale eden seçim.

ADC birimi tutarsız. Beyin içi ADC üst değerlerinin dağılımı tek bir birimle açıklanamıyordu. Vakaların bir kısmı mm^2/s , bir kısmı $\times 10^{-3}$, bir kısmı $\times 10^{-6}$ ölçeğinde geliyor. Düzeltme öncesi bu değerlerin varyasyon katsayısı 1,52 idi. Ölçek grubu vaka bazında belirlenip ortak birime taşındıktan sonra 0,09'a düştü. Düzeltme yapılmıyorsa model ikinci kanalda aynı anda üç farklı ölçek görecek. ADC bilgisi de pratikte kullanılamaz hale gelecekti.



Şekil 2. ADC üst değerlerinin dağılımı, ölçek düzeltmesi öncesi ve sonrası. Solda logaritmik eksenle üç ayrı kümelenme görülüyor. Düzeltmeden sonra dağılım tek modda toplanıyor.


Lezyon dağılımı aşırı çarpık. Medyan lezyon hacmi 6,66 mL, çeyrekler arası aralık 1,58–21,17 mL, en büyük vaka 482 mL. Vakaların 46'sında lezyon 1 mL'nin altında. Ayrıca vakaların yüzde 79,6'sı çok odaklı ve medyan

bağlı bileşen sayısı beş. Bu iki ölçüm, sonuçların tek bir ortalama Dice ile verilemeyeceğini baştan belirledi. Bütün karşılaştırmalar hacim tertiline göre kırılarak ve lezyon bazlı F1 ile birlikte raporlanıyor.

Merkez sayısı iki ve dağılım dengesiz (198 ve 52 vaka). Bölme merkez ve hacim tertiline göre stratifiye edildi. Buna karşılık merkezler arası performans farkı üzerine kurulacak her cümle küçük merkezden gelen az sayıda vakaya dayanacak. Bu nedenle söz konusu kırılım raporda öne çıkarılmıyor.

1.2 Veri hazırlığı ve bölme

Ön işleme sırası şöyle. İki seri 2 mm izotropik grid'e yeniden örnekleniyor, DWI üzerinden beyin maskesi çıkarılıyor ve hacim maskenin sınırlayıcı kutusuna kırılıyor. Ardından DWI maske içinde z-score ile normalize ediliyor, ADC ise ortak birime taşınıp sabit aralığa ölçekleniyor. Kırpma sonrası düzlem boyutları en fazla 87×101 olduğu için girdi 96×128'e dolduruldu. Kare bir boyut seçmek yüzde otuz üç fazla piksel demek olurdu.



Şekil 3. Ön işleme çıktısının doğrulanması. Üç örnek vakada normalize DWI, ölçeklenmiş ADC, referans maske ve overlay gösteriliyor. DWI beyin içi ortalaması sıfıra, standart sapması bire yakın. ADC sıfır ile bir arasında.

Bölme vaka düzeyinde yapıldı. Eğitim 161, validation 39, test 50 vaka. Aynı vakanın dilimlerinin iki kümeye dağılması, dilim tabanlı eğitimde en kolay yapılan sızıntı hatası. Lezyon içermeyen üç vaka yalnızca eğitim kümesinde tutuldu. Bu vakalar modele yanlış pozitif baskılamayı öğretiyor, ama validation ve test'te Dice'i tanımsız yapıp ortalamayı kirlendirirdi.

2. Yöntem

Dokuz koşu yapıldı. Beşi mimari karşılaştırması, dördü ablasyon. Karşılaştırmanın mimariyi ölçmesi için veri bölünmesi, ön işleme, augmentasyon zinciri, optimizier, learning rate zamanlaması ve epoch bütçesi dokuz koşuda da sabit tutuldu.

Mimariler. Taban çizgisi 2B U-Net ve ResNet34 encoder. Buna ek olarak aynı mimarinin 2.5D varyantı (beş komşu dilim, on kanal), transformer tabanlı SegFormer-B0, hafif encoder'lı MobileNetV3 ve tam hacim işleyen bir 3B U-Net denendi. 3B model başlangıçta yalnızca doğruluk tavanı olarak, gerçek zamanlı olmayan bir referans olarak konumlandırılmıştı. Ölçümler bunun yanlış olduğunu gösterdi ve konu dördüncü bölümde ele alınıyor.

Ablasyonlar. A1, FLAIR'i üçüncü modalite olarak ekliyor. A2, bölge kaybını Dice yerine focal-Tversky ile değiştiriyor ve küçük lezyonlarda recall'u hedefliyor. A3, 2.5D bağlam derinliğini $k=1$ ve $k=3$ ile tarayarak taban çizgisiyle 2.5D arasındaki farkın gerçek olup olmadığını sınıyor.

Metrikler vaka düzeyinde hesaplanıyor. Dilim başına Dice ortalaması yanıltıcı olurdu, çünkü lezyonu iki dilimde olan vaka ile kırk dilimde olan vaka eşit ağırlık alırdı. Her vakanın bütün dilimleri geçirilip hacim yeniden kuruluyor. Dice, IoU, precision, recall, HD95, mutlak hacim farkı ve lezyon bazlı F1 o hacim üzerinde ölçülüyor.

2.1 Eğitim sırasında düzeltilen iki hata

Focal-Tversky kaybı ilk uygulamasında modeli çökertti. Test Dice 0,044, precision 0,024 çıktı ve model beynin büyük bölümünü lezyon işaretliyordu. Kaybın dört senaryoda ölçülmesi sebebi gösterdi. Saf bölge kaybı bir doygunluk tuzağı yaratıyor. Model her şeyi lezyon dediğinde kayıp değeri yüksek görünüyordu ama gradyan pratikte sıfır. Sigmoid doymuş ve yanlış negatif terimi sıfırlanmış durumda. Çıkış gradyanı, yarım doğru bir tahmininkinin beş milyonda biri. Taban çizgisindeki BCE terimi tam olarak bunu engelliyordu. İkinci hata gamma parametresinin literatürdeki değerin tersi alınmasıydı. Kayıp BCE ile birleştirilip gamma düzeltildikten sonra koşu normal davrandı.


İkinci hata ölçüm tarafındaydı ve raporun sayılarını sessizce bozabilirdi. Yarım hassasiyet ölçümü için model nesnesi yerinde dönüştürülüp sonra geri çevriliyordu. Bu işlem geri dönüşümlü olmadığı için tam hassasiyet ölçümleri aslında yarım hassasiyet ağırlıklarıyla yapılıyordu. Hata, üretilen maskelerin referans değerlerle karşılaştırıldığı kalite kilidi tarafından yakalandı.

Bu iki olay raporun genel yaklaşımını da özetliyor. Her aşamada üretilen sonucun bağımsız bir referansla karşılaştırıldığı bir kontrol var ve bu kontroller birden fazla kez gerçek hata yakaladı.

3. Model sonuçları

Model	Parametre (M)	Zirve epoch	Val Dice	Test Dice	SEM	IoU	Precision	Recall	HD95 (mm)	AVD (mL)
3D U-Net	1.40	35	0.7081	0.7023	0.0327	0.5787	0.6886	0.7562	16.5821	3.7646
U-Net + ResNet34 (2D)	24.43	36	0.6777	0.6965	0.0270	0.5616	0.7540	0.6844	16.0582	2.8405
A3: k=1	24.45	35	0.6982	0.6896	0.0294	0.5575	0.7491	0.6796	16.7960	2.3954
A2: focal-Tversky	24.46	55	0.6845	0.6806	0.0295	0.5464	0.6741	0.7188	16.7997	3.6078
A3: k=3	24.47	33	0.6521	0.6796	0.0286	0.5446	0.7448	0.6596	16.2085	3.0898
U-Net + MobileNetV3	6.69	41	0.6825	0.6744	0.0296	0.5409	0.7630	0.6483	15.0817	3.0242
U-Net + ResNet34 (2.5D)	24.46	21	0.6785	0.6652	0.0324	0.5342	0.6801	0.6826	18.7037	3.2800
A1: +FLAIR	24.47	37	0.6739	0.6568	0.0332	0.5264	0.7245	0.6488	18.0303	4.2667
SegFormer-B0	3.73	34	0.6345	0.6398	0.0307	0.5026	0.6636	0.6465	18.6777	2.6662

Test kümesi 50 vaka. Val Dice checkpoint seçimi için kullanıldı, model seçimi için değil. SEM, vakalar arası standart hatayı gösteriyor.



Şekil 4. Solda dokuz koşulun test Dice değerleri, sağda aynı modellerin parametre sayısı. Gri bant, aynı mimarinin küçük varyantları arasında ölçülen koşu varyansını gösteriyor. Bu bantın içinde kalan farklar ayırt edilebilir değil ve dokuz modelin yedisi bantın içinde. Kırmızı işaretli iki model gecikme ölçümlerine taşınan adaylar. Kalite sıralaması ile model boyutu arasında bir ilişki görünmüyor. En küçük model listenin başında, ikinci en küçükü sonunda.

Dokuz koşulun tamamı 0,64 ile 0,70 arasında test Dice veriyor. Nominal sıralamada 3B U-Net önde, taban çizgisi hemen arkasında. Ancak bu sıralamayı yorumlamadan önce farkların ölçüm gürültüsünün üzerinde olup olmadığına bakmak gerekiyor.

3.1 Farklar ayırt edilebiliyor mu


Bir mimarinin kendi varyantları arasındaki fark, mimariler arasında ölçmeye çalıştığımız farkla aynı mertebede olursa sıralama anlamını yitirir. A3 ablasyonu bunu dolaylı olarak ölçmeyi sağladı. 2.5D bağlam derinliği k=1,

k=2 ve k=3 için aynı mimarının üç varyantı eğitildi. Test Dice değerleri 0,6652 ile 0,6896 arasında, yani 0,024 genişliğinde bir banda yayıldı. Bütçe nedeniyle hiçbir koşu aynı ayarla tekrarlanmadı. Dolayısıyla bu bant, elimizdeki en iyi koşu varyansı tahmini.

Aynı ablasyon ikinci bir sonuç daha verdi. Bağlam derinliği arttıkça tutarlı bir eğilim yok. k=1 taban çizgisine çok yakın, k=2 en düşük, k=3 arada. Bağlam gerçekten katkı sağlıyor ya da zarar veriyor olsaydı monoton bir yön beklenirdi. Dolayısıyla 2.5D girdinin bu görevde ölçülebilir bir katkısı yok, ama zarar verdiği de gösterilemedi.

Model	Test Dice	%95 GA	Taban çizgisine göre fark	Farkın %95 GA	Wilcoxon p	Holm sonrası
3D U-Net	0.7023	0.634 - 0.761	+0.0058	-0.040 - +0.046	0.0844	anlamli degil
U-Net + ResNet34 (2D)	0.6965	0.640 - 0.745	-	-	-	referans
A3: k=1	0.6896	0.628 - 0.743	-0.0069	-0.034 - +0.018	0.6652	anlamli degil
A2: focal-Tversky	0.6806	0.619 - 0.734	-0.0159	-0.048 - +0.014	0.1714	anlamli degil
A3: k=3	0.6796	0.620 - 0.733	-0.0169	-0.038 - +0.003	0.0844	anlamli degil
U-Net + MobileNetV3	0.6744	0.614 - 0.729	-0.0221	-0.051 - +0.006	0.0048	ANLAMLI
U-Net + ResNet34 (2.5D)	0.6652	0.597 - 0.724	-0.0313	-0.066 - -0.002	0.0249	anlamli degil
A1: +FLAIR	0.6568	0.589 - 0.718	-0.0397	-0.080 - -0.004	0.0011	ANLAMLI
SegFormer-B0	0.6398	0.577 - 0.696	-0.0567	-0.084 - -0.030	<0,0001	ANLAMLI

Güven aralıkları, vaka düzeyinde 10.000 yeniden örnekleme ile hesaplandı. Fark sütunları eşleştirilmiş. Her yeniden örnekleme adımında iki model aynı vaka indekslerini kullanıyor. Holm düzeltmesi sekiz karşılaştırma üzerinden yapıldı.



Şekil 5. Taban çizgisine göre eşleştirilmiş fark ve yüzde 95 güven aralığı. Yıldızlı satırlar Holm düzeltmesinden sonra anlamlı kalan farklar. Gri bant koşu varyansı aralığını gösteriyor.

Mutlak Dice değerlerinin güven aralıkları dokuz modelde de geniş ölçüde üst üste biniyor ve tek başlarına hiçbir modeli diğerinden ayıramıyorlar. Eşleştirilmiş farkların aralıkları ise belirgin şekilde dar. Sebep, varyansın büyük kısmının vaka zorluğundan gelmesi. Aynı vakalar üzerinde eşleştirme bu ortak varyansı düşürüyor.

Holm düzeltmesinden sonra taban çizgisinden ayrılan üç model var. Bunlar SegFormer-B0, FLAIR ablasyonu ve MobileNetV3 varyantı. Üçü de daha kötü yönde. Hiçbir alternatif taban çizgisini geçmedi. 3B U-Net'in nominal üstünlüğü ise anlamlılık eşiğine ulaşmıyor ve etkisi koşu varyansı bandının içinde kalıyor.

İki prosedür iki modelde birbiriyle çelişiyor. MobileNetV3 için Holm anlamlı diyor, ama farkın güven aralığı sıfırı içeriyor. 2.5D varyantı için tersi geçerli. Sebep, Wilcoxon testinin sıra tabanlı olması ve tutarlı işaret örüntüsüne duyarlı olması. Bootstrap aralığı ise ortalama üzerinde çalışıyor ve birkaç uç vakadan etkileniyor. Bu iki model sınırda sayılıyor ve tek bir prosedüre dayanarak anlamlı ilan edilmiyor.

3.2 Lezyon boyutuna göre kırılım


Model	Küçük tertil	Orta tertil	Büyük tertil	Lezyon F1	Lezyon sayı farkı
3D U-Net	0.5541	0.7111	0.8330	0.5698	4.3400
U-Net + ResNet34 (2D)	0.5638	0.6953	0.8226	0.5717	3.6400
A3: k=1	0.5353	0.6958	0.8286	0.5219	4.7400
A2: focal-Tversky	0.5296	0.6901	0.8133	0.4869	4.6800
A3: k=3	0.5382	0.6720	0.8204	0.4865	4.7000
U-Net + MobileNetV3	0.5453	0.6554	0.8148	0.4918	4.3800
U-Net + ResNet34 (2.5D)	0.4929	0.6780	0.8146	0.4820	4.7400
A1: +FLAIR	0.5387	0.6140	0.8107	0.4557	5.1600
SegFormer-B0	0.4539	0.6558	0.7989	0.4416	5.6600

Hacim tertilleri 250 vaka üzerinden tanımlandı. Test kümesindeki dağılım 16, 17 ve 17 vaka. Lezyon F1, bağlı bileşen eşleştirmesiyle hesaplandı (IoU eşiği 0,1).


Ortalama Dice'in gizlediği en büyük örüntü burada. Taban çizgisinde küçük lezyonlarda Dice 0,564, büyük lezyonlarda 0,823. Aradaki 0,26'lık fark, modeller arasındaki en büyük farkın on katından fazla. Dokuz koşunun hiçbirisi küçük tertilde 0,564'ü geçemedi ve bu değeri veren model taban çizgisi. Küçük lezyonları doğrudan hedefleyen tek ablasyon focal-Tversky, o tertilde durumu kötüleştirdi. Kaybın ürettiği ek recall küçük lezyonlara değil, zaten bulunan lezyonların çevresine gitti ve mutlak hacim farkı büyüdü.

Lezyon bazlı F1 ters yönde çalışıyor. Büyük lezyonlarda Dice en yüksek olmasına rağmen lezyon F1 en düşük. Sebep, büyük infarktların tek kütle olmaması. Ana lezyonun yanında uydu bileşenler bulunuyor ve bunların hepsini yakalamak bileşen düzeyinde sayımda daha zor.

3.3 Eğitim davranışı




Şekil 6. Taban çizgisinin eğitim eğrileri. Train ve validation kayıpları hiç ayırmıyor. Learning rate sekiz kez düşürüldüğü için val Dice zirvesine ulaştığında öğrenme oranı başlangıç değerinin on altıda birine inmiş durumda.



Şekil 7. 3B U-Net eğitim eğrileri. Train ve validation kayıpları arasındaki makas açılıyor ve bu, çalışmadaki tek aşırı öğrenme örüntüsü. Learning rate hiç düşmedi. Koşu yakınsadığı için değil, val Dice on beş epoch iyileşmediği için durdu.

İki koşu farklı davranıyor. Taban çizgisinde train ve validation kayıpları hiç ayrıışmıyor. Son epoch'ta validation kaybı train'in bile hafif altında, çünkü train augmented edilmiş dilimler üzerinde ölçülüyor. Yani kapasite ya da epoch bütçesi sınırlayıcı değil. 3B modelde ise makas açılıyor ve bu, çalışmada aşırı öğrenme gösteren tek koşu. 161 hacim, dilim tabanlı eğitimden çok daha az çeşitlilik sunuyor.

Learning rate zamanlaması iki koşuda tersine çalıştı. Taban çizgisinde validation kaybı erken platoya girdi ve learning rate sekiz kez düşürüldü. Val Dice zirvesine ulaştığında öğrenme oranı başlangıç değerinin on altıda birine inmişti. 3B modelde ise validation kaybı plato koşulunu hiç sağlamadı ve learning rate hiç düşmedi. Koşu yakınsadığı için değil, val Dice on beş epoch iyileşmediği için durdu. Protokol dokuz koşuda sabit tutulduğu için değiştirilmedi, ancak bu iki modelin epoch bütçesine sıkışmış olabileceği kayda geçiyor.



Şekil 8. Sabit değeriendirme vakaları. Sütunlar sırasıyla DWI, referans maske, tahmin ve overlay. Vakalar hacim aralığına yayılmış olarak seçildi. En üstteki vaka 0,21 mL, en alttaki 93 mL. Küçük lezyonlardaki düşük doğruluk görsel olarak da izlenebiliyor.

4. Gecikme


Bu bölümün sorusu, hattın klinik akışta kabul edilebilir bir sürede çalışıp çalışmadığı. Literatürdeki referans noktaları iki uç veriyor. Aynı veri setinin yayınlanmış en iyi modeli olan DeepISLES vaka başına yaklaşık iki dakika sürüyor. Buna karşılık ONNX ve yarım hassasiyetle optimize edilmiş bir nnU-Net dağıtım aracı olan StrokeSeg, hacim başına 0,9 saniye bildiriyor. Hedef, vaka başına uçtan uca iki saniyenin altı, tercihen bir saniyenin altı olarak belirlendi.

Ölçüm protokolü şöyle. Ölçülen şey ön işleme, ileri geçiş ve son işlemenin toplamı. Diskten okuma bütçenin dışında tutuluyor, çünkü servis senaryosunda hacim görüntüleme sisteminden geliyor. Yine de ayrı bir sütunda raporlanıyor. Isınma koşulları atılıyor ve her vaka tek tek senkronlanarak ölçülüyor. Bütün ölçümler yerel bir RTX 2060 üzerinde, eğitimin yapıldığı ortamdan bağımsız olarak alındı.

4.1 Darboğaz modelde değil ön işlemede

Ön işleme	Hassasiyet	Ön işleme (ms)	Ağ (ms)	Toplam (ms)
CPU	fp32	305.7	78.6	385.1
CPU	fp16	328.1	43.2	372.2
GPU	fp32	83.3	66.9	151.4
GPU	fp16	95.3	41.7	138.4

3B U-Net, 25 test vakası. Her satırda model taze yüklenip ilgili hassasiyete çevriliyor.



Şekil 9. Vaka başına sürenin bileşenlere dağılımı. Ön işlemenin GPU'ya taşınması toplam süreyi üçte birine indiriyor. Yarım hassasiyet ağ süresini yarıya düşürüyor. Kesikli çizgi hedeflenen üst sınırı gösteriyor.

İlk ölçüm, optimizasyon çabasının yanlış yere yöneldiğini gösterdi. Tam hassasiyette ve CPU ön işlemesiyle vaka başına sürenin dörtte üçü ön işlemeye gidiyor. Ağ payı yüzde yirmi civarında. Planlanan optimizasyon merdiveni ise tamamen ağı hedefliyordu. Ağ süresi tamamen sıfırlansaydı bile toplam ancak dörtte bir azalırdı.

Ön işlemenin kırılımı üç adıma işaret ediyor. Bunlar iki yeniden örnekleme ve beyin maskesi. Üçü de CPU'da scipy ve nibabel ile çalışıyordu. Yeniden örnekleme, nibabel'in uygulamasıyla aynı çıktı grid'ini kullanan bir grid_sample çağrısına dönüştürüldü. Hedef grid nibabel'in kendi fonksiyonundan alındığı için değişen tek şey örnekleme'nin nerede yapıldığı. On iki vakada bağıl sapma 10^{-5} mertebesinde kaldı.


Bu dönüşüm sırasında bir tuzak çıktı. scipy, girdi sınırının dışındaki noktalara sabit değer verirken grid_sample kenarda iç değerle sıfırı harmanlıyor. Eğik affine taşıyan vakalarda bu, hacim sınırında birkaç yüz voxel'de büyük farklar ürettiyordu. Geçerlilik maskesi eklenerek iki davranış eşitlendi.

Beyin maskesinde eşikleme ve morfolojik kapama GPU'ya taşındı. Delik doldurma ve bağlı bileşen etiketleme ise GPU'da ucuz karşılığı olmadığı için tam çözünürlükte CPU'da bırakıldı. Bu iki adımı alt örneklenmiş bir maskede yapmak daha hızlıydı, ancak kırpma kutusunu bir voxel kaydırıp çıktığı değiştiriyordu. Hız uğruna sonucu değiştirmek kazanç sayılmadığı için geri alındı.

4.2 Ağ optimizasyonu ve arka uç seçimi

Arka uç	Ön işleme (ms)	Ağ (ms)	Son işleme (ms)	Toplam (ms)	Std (ms)	Dice	Referanstan en büyük sapma	Kalite kilidi
torch-fp32	86.40	68.22	11.48	166.10	19.99	0.67	0.00	GECTI
torch-fp16	83.82	42.46	11.54	137.82	22.97	0.67	0.00	GECTI
onnx-cuda	92.22	76.78	10.54	179.55	22.08	0.67	0.00	GECTI
trt-fp16	89.99	41.99	10.95	142.92	20.50	0.67	0.00	GECTI

Servis hattında, 25 test vakası. Kalite kilidi, üretilen maskenin vaka başına referans Dice değerinden sapmasını kontrol ediyor. Tolerans 0,002.



Şekil 10. Solda dört arka ucun uçtan uca süresi. Sağda aynı ağların izole ölçümdeki ve gerçek hattaki süreleri. TensorRT'nin izole ölçümdeki üstünlüğü vaka başına çalışmada kayboluyor.

Yarım hassasiyet, ağ süresini yaklaşık yarıya indiriyor ve Dice'a etkisi ölçülemez düzeyde kalıyor. Referanstan sapma tam hassasiyetteki sapmadan büyük değil. ONNX Runtime ise tam hassasiyette hiçbir kazanç sağlamıyor. Bu, benzer bir çalışmada ONNX'in çerçeve yükünü kaldırarak iki ila üç kat hızlanma vermesiyle çelişiyor gibi görünüyor. Aradaki fark, orada kare başına Python yükünün amorti edilmemiş olması. Burada 3B model vaka başına tek ileri geçiş yapıyor, dolayısıyla kaldırılacak bir çerçeve yükü yok.

Arka uç	İzole ölçüm (ms)	Servis hattı (ms)	Oran
torch-fp32	66.40	68.22	1.03
torch-fp16	27.80	42.46	1.53
onnx-cuda	63.02	76.78	1.22
trt-fp16	14.46	41.99	2.90


İzole ölçüm, aynı girdi dizisi otuz kez arka arkaya beslenerek yapıldı. Servis hattı sütunu, vaka başına taze girdiyle ölçülen süreler.

TensorRT sonucu özellikle dikkat çekici. İzole ölçümde 3B model için TensorRT, PyTorch'un yarım hassasiyetli halinden yaklaşık iki kat hızlı görünüyordu. Gerçek hatta ikisi aynı süreyi veriyor ve oturum yükü nedeniyle TensorRT toplamda birkaç milisaniye geride kalıyor. İzole ölçümde aynı dizinin tekrar tekrar beslenmesi, çalışma zamanının giriş bağlamalarını ve cihaz tamponlarını amorti etmesine yol açıyor. Vaka başına taze veriyle bu kazanç ortadan kalkıyor. Sonuç olarak dağıtım için PyTorch ve yarım hassasiyet seçildi. Aynı hız, çok daha basit bir yığın. ONNX dışı aktarımı, TensorRT sürüm eşleşmesi ve motor önbelleği gereksiz hale geliyor.

İzole ağ ölçümleri dağıtılabılır sayı değil. Bu çalışmada iki kez, birbirinin tersi yönde yanıltıcı sonuç verdiler. Karar her seferinde uçtan uca ölçümle verildi.

5. Eşik, son işleme ve metrik doğrulaması

Karar eşiği ve küçük bileşen eleme eşiği validation kümesinde seçilip test'e tek sefer uygulandı. Test üzerinde tarama yapmak elli vakaya uydurmak olur ve raporlanan sayıları iyimser gösterirdi.



Şekil 11. Validation kümesinde eşik taraması. İki model ters yönlerde gidiyor. Aşırı segmentasyon eğilimindeki 3B model daha yüksek, muhafazakâr 2B taban çizgisi daha düşük eşik seçiyor. Kazanç iki modelde de binde üç mertebesinde.

Model	Ayar	Dice	Precision	Recall	HD95 (mm)	AVD (mL)	Lezyon F1
3D U-Net	once (0,50 / 0)	0.7023	0.6886	0.7562	16.5821	3.7646	0.5698
3D U-Net	sonra (0.70 / 0)	0.7063	0.7098	0.7421	15.8338	3.2302	0.5811
U-Net + ResNet34 (2D)	once (0,50 / 0)	0.6965	0.7540	0.6844	16.0582	2.8406	0.5717
U-Net + ResNet34 (2D)	sonra (0.20 / 0)	0.6957	0.7203	0.7122	17.7509	2.8086	0.5497

Validation kümesinde seçilen ayarın test kümesindeki etkisi. Her model için üst satır varsayılan ayar, alt satır seçilen ayar.

Eşik taraması iki modeli ters yönlerde götürdü. 3B model aşırı segmentasyon eğiliminde olduğu için daha yüksek bir eşik seçti. 2B taban çizgisi ise muhafazakâr olduğu için daha düşük bir eşik seçti. Ancak

validation'daki kazanç iki modelde de binde üç mertebesinde kaldı. Test'e taşındığında yalnızca 3B modelde küçük bir iyileşme üretti. Eşik ayarı bu görevde anlamlı bir kaldıraç değil.

Küçük bileşen eleme her iki modelde de zarar verdi ve uygulanmadı. Bunun sebebi veri keşfinde görülmüştü. Referans maskelerin kendisinde beş voxel'in altında 897 bağlı bileşen var, dolayısıyla eleme yalnızca yanlış pozitifleri değil gerçek lezyonları da siliyor. Yine de bir takas görünür oldu. Taban çizgisinde beş voxel'lik eleme Dice'ı binde beş düşürürken lezyon F1'i altmış binde yükseltiyor. Seçim Dice üzerinden yapıldığı için eleme yok. Öncelik lezyon tespiti olsaydı karar tersine dönerdi.

5.1 Lezyon bazlı F1'in doğrulanması

Vaka	panoptica RQ	Bu çalışmanın uygulaması	Fark
0001	0.6939	0.6939	0.0000
0004	0.7143	0.7143	0.0000
0007	0.0000	0.0000	0.0000
0008	0.6000	0.6000	0.0000
0010	0.5217	0.5217	0.0000
0016	0.0000	0.0000	0.0000
0020	0.8571	0.8571	0.0000
0022	1.0000	1.0000	0.0000
0029	0.6667	0.6667	0.0000
0031	0.4242	0.4242	0.0000

Rastgele seçilen on test vakası. panoptica, ISLES challenge'ının resmi değerlendirme aracı. RQ metriği bileşen düzeyinde F1'e karşılık geliyor.

Eğitim döngüsünde hızlı bir kendi uygulamamız kullanıldı. Bu uygulamanın resmi araçla aynı tanımı hesapladığı on vakada doğrulandı. Değerler ondalık basamağına kadar aynı ve korelasyon 1,000. Buna karşılık metriğin kendisi eşleştirme eşliğine güçlü biçimde bağlı. Aynı tahminler üzerinde herhangi bir örtüşme yeterli sayıldığında lezyon F1 0,609 çıkıyor. IoU eşiği 0,5'e çıkarıldığında aynı değer 0,399'a düşüyor. Bu nedenle lezyon F1 değerleri raporda daima eşleştirme eşiğiyle birlikte veriliyor ve literatürdeki değerlerle doğrudan karşılaştırılmıyor.

6. Servis

Çıkarım hattı çalışır bir servise dönüştürüldü. Servis, ham NIfTI dosyalarını alıp infarkt maskesi, lezyon hacmi, bağlı lezyon sayısı, en büyük lezyonun hacmi ve hemisfer bilgisini döndürüyor. Ayrıca tek dosyalık bir vaka raporu üretiyor. Rapor dilim mozaigini ve vakanın hacminin veri seti dağılımındaki konumunu gösteriyor. Her yanıtta işlem süresi bileşenlere ayrılmış olarak loglanıyor.

Motor uygulama açılışında bir kez yükleniyor. Bunun önemi ölçüldü. İlk gerçek istek ısıtma olmadan 331 milisaniye sürüyordu, yani kararlı halin üç katından fazla. Yalnızca ağ ısıtmak yeterli olmadı, çünkü yeniden örnekleme ve morfoloji çekirdekleri de ilk çağrılarında yavaş. Açılışta sentetik bir hacim tüm hattan geçirilerek ısıtma yapıldığında ilk istek 85 milisaniyeye indi.


Ayrıca ön işleme ile ağ arasındaki gereksiz bellek transferi kaldırıldı. Ön işleme GPU'da bitip sonuç ana belleğe iniyor, ağ için tekrar GPU'ya çıkıyordu. 3B modelde girdi doğrudan GPU'da kurulabildiği için bu gidiş dönüş ortadan kalktı.

6.1 Klinik çıktı ve sınırlılıkları

Hacim, 2 mm yeniden örneklenmiş grid üzerinden hesaplanıyor. Orijinal grid'e göre ölçülen sistematik fark ortalamada ihmal edilebilir. Buna karşılık standart sapması yüzde 2,3 ve çok küçük lezyonlarda yüzde on ikiye kadar çıkabiliyor. Klinik hacim raporlanırken bu taban belirtiliyor.

Hemisfer bilgisi, yeniden örnekleme sırasında hacim kanonik yöne getirildiği için lezyon voxel'lerinin sol-sağ eksenine üzerindeki dağılımından çıkarılıyor. Üçte ikiden fazlası bir tarafta yoğunlaşmıyorsa bilateral olarak işaretleniyor.

6.2 FLAIR ablasyonunun maliyeti



Şekil 12. FLAIR hizalamasının görsel doğrulaması. Son panelde DWI kırmızı, hizalanmış FLAIR yeşil kanalda. Beyin sınırlarının örtüşmesi header tabanlı taşımanın kabaca doğru çalıştığını gösteriyor.

FLAIR serisi hiçbir vakada DWI ile aynı grid'de değil. Yirmi iki farklı matris boyutu ve yirmi bir farklı voxel aralığı var. Kullanabilmek için vaka başına hizalama gerekiyor ve bu hizalama, ölçülen değerlere göre vaka başına 670 milisaniye sürüyor. Bu, tüm çıkarım hattının beş katından fazla. Ablasyon ayrıca doğruluk tarafında da olumsuz sonuç verdi. Bu iki gerekçe FLAIR'i gerçek zamanlı yapılandırmanın dışında bırakıyor. Yalnız bir ayırım korunmalı. Hizalama NIfTI header'ları üzerinden yapıldı ve yoğunluk tabanlı kayıt denenmedi. Dolayısıyla sonuç, FLAIR'in bilgi taşımadığını değil, ucuz hizalamayla zarar verdiğini gösteriyor.

7. Sınırlılıklar

- Test kümesi 50 vaka. Bu boyutta 0,02 mertebesindeki farklar güvenilir biçimde ayrılamıyor. Raporun sıralama yerine ayırt edilebilirlik üzerine kurulmasının sebebi bu.
- Hiçbir koşu tekrarlanmadı. Koşu varyansı, aynı mimarinin üç varyantından dolayı olarak tahmin edildi (yaklaşık 0,024). Bu tahmin üç ölçümden geliyor ve kendisi de gürültülü.
- Tek veri kaynağı. ISLES 2022 iki merkezden geliyor ve dış doğrulama yapılmadı. Farklı cihaz ve protokollere genelleme bu çalışmayla gösterilmiş değil.
- Core ve penumbra ayrımı üretilmiyor. Veri setinde perfüzyon serisi bulunmadığı için reperfüzyon kararının dayandığı mismatch oranı hesaplanamıyor.

- Küçük lezyonlar çözülmedi. En küçük hacim tertilinde Dice 0,55 civarında kalıyor ve bunu hedefleyen ablasyon durumu kötüleştirdi. Sebep araştırılmadı.
- FLAIR ablasyonu yalnızca ucuz hizalamayla yapıldı. Yoğunluk tabanlı kayıt denenmedi.
- Epoch bütçesi bazı koşullarda sınırlayıcı olmuş olabilir. 3B model ve focal-Tversky ablasyonu bütçe tavanına dayandı. Protokol dokuz koşulda sabit tutulduğu için uzatılmadı.
- INT8 nicemleme ve pruning ölçülmedi. Yarım hassasiyetten sonra ağ, uçtan uca bütçenin üçte birinden azını oluşturuyor, dolayısıyla beklenen kazanç birkaç milisaniye. Buna karşılık kalibrasyon kümesinin hazırlanması ve doğrulanması ayrı bir iş kalemi. Literatürde 3B segmentasyon modellerinde INT8'in Dice'ı büyük ölçüde koruduğu bildiriliyor. Yani atlanan adım kalite riski değil, ölçülmemiş bir kazanç.
- Gecikme ölçümleri, üzerinde başka uygulamalar çalışan bir masaüstü makinede alındı. GPU tarafındaki ölçümler oturumlar arasında tekrarlanabilir çıktı. CPU'ya bağlı ön işleme süreleri ise sistem yüküne duyarlı ve oturumlar arasında yüzde otuza varan oynama gösterdi.

8. Sonuç

Kalite. Dokuz koşulunun hiçbirisi basit 2B U-Net taban çizgisini geçemedi. Denenen dört fikirden üçü, yani transformer encoder, hafif encoder ve FLAIR eklenmesi, istatistiksel olarak anlamlı biçimde daha kötü sonuç verdi. 2.5D bağlam ise ne fayda ne zarar gösterdi. 3B U-Net nominal olarak en yüksek Dice'ı veriyor, ancak fark koşu varyansı bandının içinde kalıyor ve anlamlılık eşiğine ulaşmıyor. Tek bir en iyi model ilan etmek eldeki ölçümlerle desteklenmiyor.

Seçim ölçütü. Kalite ayırt edici olmadığı için karar maliyet eksenine kayıyor. 3B U-Net 1,40 milyon parametreyle taban çizgisinin on yedide biri büyüklüğünde ve nominal Dice'ı biraz daha yüksek. Dağıtım için bu model seçildi. Gerekçe hız değil, boyut ve kalite açısından kötü olmaması.

Hız. Gerçek zamanlılık modelden değil ön işlemeden geldi. Yeniden örnekleme ve beyin maskesinin GPU'ya taşınması vaka başına süreyi yaklaşık dörtte birine indirdi. Yarım hassasiyet ağ süresini bir kat daha azalttı. Sonuç, vaka başına yaklaşık 138 milisaniyelik bir hat. Bu, hedeflenen bir saniyelik üst sınırın yedide birinden az. Aynı veri setinin yayınlanmış en iyi modelinin bildirdiği sürenin ise yaklaşık sekiz yüzde biri. ONNX ve TensorRT bu hatta kazanç sağlamadı ve dağıtım yığınının çıkarıldı.

Klinik kullanım. Üretilen çıktı tek bir infarkt maskesi ve ondan türetilen hacim bilgisi. Core ve penumbra ayrımı yapılamıyor, küçük lezyonlarda doğruluk belirgin biçimde düşük ve model tek bir veri kaynağının dağılımına göre eğitildi. Bu haliyle sistem, uzman değerlendirmesini destekleyen bir ön işaretleme aracı olarak değerlendirilebilir. Tanı ya da tedavi kararı için kullanılamaz.

Sonraki aşama. Üç yön öne çıkıyor. Küçük lezyonlardaki düşük doğruluk, çalışmanın çözülmemiş ana problemi ve ayrı bir çalışma konusu. Koşulların tekrarlanması, sıralama hakkında söylenebilecekleri güçlendirir. Farklı bir merkezden gelen bağımsız bir veri kümesiyle dış doğrulama ise klinik değerlendirmenin ön koşulu.

Kaynaklar

1. Hernández Petzsche MR, de la Rosa E, Hanning U, vd. (2022). ISLES 2022: A multi-center magnetic resonance imaging stroke lesion segmentation dataset. Scientific Data, 9, 762. [10.1038/s41597-022-01875-5](https://doi.org/10.1038/s41597-022-01875-5) — zenodo.org/records/7960856
2. de la Rosa E, vd. (2025). DeepISLES: a clinically validated ischemic stroke segmentation model from the ISLES'22 challenge. Nature Communications, 16, 7357. [10.1038/s41467-025-62373-x](https://doi.org/10.1038/s41467-025-62373-x)

3. Abraham N, Khan NM (2019). A novel focal Tversky loss function with improved attention U-Net for lesion segmentation. IEEE International Symposium on Biomedical Imaging (ISBI). [10.1109/ISBI.2019.8759329](https://doi.org/10.1109/ISBI.2019.8759329)
4. Kofler F, Möller H, Buchner JA, de la Rosa E, vd. (2023). Panoptica: instance-wise evaluation of 3D semantic and instance segmentation maps. [arXiv:2312.02608](https://arxiv.org/abs/2312.02608)
5. Kerverdo Y, Leray F, Mahé Y, Leplaideur S, Galassi F (2025). Stroke Lesion Segmentation in Clinical Workflows: A Modular, Lightweight, and Deployment-Ready Tool. [arXiv:2510.24378](https://arxiv.org/abs/2510.24378) — bölüm 4'te alıntılanan vaka başına 0,9 saniyelik süre bu çalışmadan.
6. Qu C, Zhao R, Yu Y, vd. (2025). Post-Training Quantization for 3D Medical Image Segmentation: A Practical Study on Real Inference Engines. [arXiv:2501.17343](https://arxiv.org/abs/2501.17343)
7. Ischemic Stroke Lesion Segmentation Challenge. isles-challenge.org