

Mamografi ile Meme Kanseri Tahmini

Derin öğrenme literatürünün iki kollu değerlendirilmesi: tespit ve sınıflandırma, risk tahmini · 2020–2026

1. Amaç ve kapsam

Bu rapor mamografi üzerinde derin öğrenme ile meme kanseri tahmini alanını 2020–2026 döneminde inceliyor. Alan tek bir problem gibi görünüyor ama değil. İki ayrı kol var ve bunlar farklı veri, farklı metrik ve farklı klinik senaryo taşıyor. Raporun kurgusu bu ayrım üzerine oturuyor, çünkü iki kolun sayılarını yan yana koymak yanıltıcı sonuç veriyor.

Birinci kol tanısal tespit ve sınıflandırma. Elde bir mamogram var, içinde kitle ya da kalsifikasyon aranıyor ve bulunan lezyonun iyi mi kötü mü huylu olduğu soruluyor. Tipik metrikler sınıflandırmada AUC, duyarlılık ve özgüllük, tespitte mAP, IoU ve FROC. İkinci kol prognostik risk tahmini. Şu anda kanser bulgusu olmayan bir kadında önümüzdeki bir ile beş yıl içindeki kanser olasılığı hesaplanıyor. Metrikler 1–5 yıllık AUC ve C-indeksi; gerekli veri ise uzun takipli tarama kohortları, çünkü etiket görüntünün kendisinde değil takip kaydında.

Kısa sonuç şu. Birinci kolda mimari CNN'lerden transformer ve vizyon-dil temel modellerine kaymış durumda, ama küçük ve dengesiz veri setlerinde bildirilen yüzde 99–100 doğruluk değerleri gerçek tarama koşullarını yansıtmıyor. Gerçekçi ölçekte, 2023 RSNA yarışmasında değerlendirilen 1.537 algoritmanın en iyisi yüzde 48,6 duyarlılık ve yüzde 99,5 özgüllük verdi; medyan algoritma yüzde 27,6 duyarlılıkta kaldı [3]. İkinci kolda referans model Mirai; geliştiricinin kendi test kümelerinde C-indeksi 0,76–0,81, bağımsız popülasyonlarda 0,63'e kadar düşüyor [17, 27]. İki kolun ortak darboğazı aynı: dış doğrulama. Lowry ve arkadaşlarının 41 çalışmalık risk derlemesinde çalışmaların tamamı retrospektif ve yalnızca altısı kalibrasyon değerlendirmiş [30].

2. Yöntem

Tarama PubMed, Scopus, Web of Science, arXiv, Papers with Code ve Semantic Scholar üzerinden yürütüldü. İki başlangıç noktası kullanıldı. Birincisi her kol için bir PRISMA sistematik derlemesi: Kol 1 için Amin ve arkadaşları [1], Kol 2 için Lowry ve arkadaşları [30]. İkincisi atıf kartopu: Mirai [17] ve AsymMirai [20] düğümlerinden ileri ve geri atıf grafiği izlendi, VinDr-Mammo ve EMBED veri seti makalelerinin atıfları taranarak bu kümeleri kullanan yeni modeller bulundu.

Kullanılan sorgular aşağıda. Bunlar raporun tekrar üretilebilmesi için veriliyor.

PubMed, Kol 1:

("Mammography"[Mesh]) AND ("Deep Learning"[Mesh] OR "Neural Networks, Computer"[Mesh])
AND ("Early Detection of Cancer"[Mesh] OR "diagnosis"[Subheading])

PubMed, Kol 2:

("Mammography"[Mesh]) AND ("Risk Assessment"[Mesh]) AND ("Deep Learning"[Mesh])
AND ("Breast Neoplasms"[Mesh])

Derleme filtresi: AND (systematic[sb] OR "systematic review"[Publication Type])

Scopus / Web of Science:

TITLE-ABS-KEY(mammography AND ("deep learning" OR "convolutional neural network"
OR transformer) AND (classification OR detection OR segmentation)
AND ("systematic review" OR PRISMA))

TITLE-ABS-KEY(mammography AND "deep learning" AND ("risk prediction"
OR "future breast cancer") AND ("external validation" OR PRISMA))

arXiv (cat:eess.IV OR cat:cs.CV):

mammography transformer classification / mammogram multi-view Swin
longitudinal mammogram risk prediction / mammography foundation model self-supervised

Rapora giren her sayısal değer kaynağın kendi özeti ya da tam metni üzerinden ayrıca doğrulandı. Doğrulanamayan değerler metne alınmadı. İkincil kaynaklarda geçen ama başka bir çalışmaya ait olan sonuçlar, ikincil kaynağa değil asıl çalışmaya atfedildi. Rapor dolayısıyla taranan tüm literatürü değil, doğrulanmış kaynakları temsil ediyor; sistematik derlemelerin kendisi birkaç yüz makalelik daha geniş bir havuzu kapsıyor.

3. Kol 1: tespit ve sınıflandırma

3.1 Alanın görünümü ve mimari evrim

Amin ve arkadaşlarının PRISMA derlemesi 1.051 kaydı tarayıp 287 makaleyi dahil ederek alanı haritalıyor [1]. Çalışmaların çoğunluğu lezyon sınıflandırmasına odaklanmış; tespit, segmentasyon ve meme yoğunluğu değerlendirmesi görece daha az çalışılmış. Yıllık üretim 2018'de 15 makaleden 2023'te 86'ya çıkmış, yaklaşık altı kat artış. Fajrin ve Min'in 2018–2025 arasını kapsayan ikinci derlemesi de benzer bir tablo veriyor ve hibrit/ensemble yaklaşımların payının arttığını gösteriyor [2].

Mimari evrim şu hattı izliyor: CNN aileleri (ResNet, VGG, DenseNet, EfficientNet), sonra dikkat mekanizmaları, sonra vizyon transformerları (ViT, Swin), sonra hibrit CNN–self-attention, en son vizyon-dil temel modelleri. Amin derlemesinin 2024–Haziran 2025 ek taramasında dört yükselen eğilim belirlenmiş: transformer mimarileri, çok görünümlü analiz, çok modlu adaptasyonlar ve yeni veri setleri [1].

3.2 Lezyon tespiti

Tespit tarafında YOLO ailesi baskın. Shia ve Ku, YOLOv8-m ile mikrokalsifikasyon tespitinde 11.303 görüntü ve 5.712 kadınlık bir kümede mAP50 0,921, mAP50-95 0,709, F1 0,82 ve recall 0,796 bildiriyor [5]. Ho ve arkadaşları YOLOv9'u OPTIMAM üzerinde ön eğitip özel veriyle ince ayar yaptığında mAP yüzde 73,3 ($\pm 16,7$) ve F1 yüzde 76,0 ($\pm 13,4$) elde ediyor; aynı kurulumda YOLOv7'ye göre mAP'te 8,1 puanlık üstünlük var [6]. İki sonuç arasındaki büyük fark veri setlerinin zorluğundan geliyor, mimariden değil.

Faster R-CNN tarafında sık alıntılanan sonuç, INbreast üzerinde görüntü başına 0,3 yanlış pozitifte yüzde 92 duyarlılık. Bu sonuç Agarwal ve arkadaşlarına ait [7]. Literatürde bu değer zaman zaman Famouri ve arkadaşlarının çalışmasına atfediliyor, ancak o çalışma sonucu yalnızca alınıyor; kendi deneyleri CBIS-DDSM üzerinde anotasyon gürültüsünün etkisini ölçüyor ve gürültülü kutularla FROC eğrisi altındaki alanın yüzde 9'a kadar düştüğünü gösteriyor [8].

3.3 Sınıflandırma ve temel modeller

Çok görünümlü transformerlar öne çıkıyor. MV-Swin-T, kaydırmalı pencere tabanlı dinamik dikkat bloğuyla CC ve MLO görünümelerini birlikte işliyor ve görünümler arası korelasyonu uzamsal öznitelik haritası seviyesinde taşıyor; CBIS-DDSM ile VinDr-Mammo üzerinde değerlendirilmiş [9]. Mammo-Clustering ise context clustering tabanlı üç seviyeli füzyonla lezyon lokalizasyonu ve sınıflandırmayı birleştiriyor [11].

Vizyon-dil temel modeli Mammo-CLIP, mamogram-rapor çiftleriyle ön eğitiliyor ve Mammo-FACTOR modülüyle cümle seviyesinde öznitelik atfı sağlıyor; bu hem yorumlanabilirlik hem de veri verimliliği getiriyor [10]. MammoDINO, DINOv2 çerçevesi üzerine kurulu self-supervised bir alternatif. 1,4 milyon mamogram üzerinde ön eğitilmiş, meme dokusuna kısıtlı augmentasyon örnekleyici ve DBT hacminde komşu kesitler arasında tutarlılık zorlayan bir kayıp kullanıyor [12]. İki modelin ortak vaadi aynı: etiketli veri ihtiyacını düşürmek.

3.4 Meme yoğunluğu değerlendirmesi

Dört sınıflı BI-RADS yoğunluk sınıflandırması, alanın dış doğrulama kırılganlığını en net gösteren görev. Khara ve arkadaşları 69.697 çalışma, 451.642 görüntü ve 23.057 kadınlık çeşitli bir kümede, yalnızca FFDM ile eğitilen modelin FFDM üzerinde yüzde 80,5, hiç görülmemiş sentetik 2D verisinde yüzde 79,4 doğruluk verdiğini bildiriyor; her iki modaliteyle eğitildiğinde bu değer ikisinde de yüzde 82,3'e çıkıyor [13]. Aynı çalışma ırk alt gruplarında yanlılık bulmuyor, ancak görüntüden ırkın yüzde 86,7 doğrulukla tahmin edilebildiğini de gösteriyor.

Karşı örnek dış doğrulamadan geliyor. Ticari bir yoğunluk modeli iki sınıflı yoğun ve yoğun değil ayrımında iyi çalışırken, dört sınıflı ayrımında ortalama yüzde 56,7 doğruluk ve Cohen kappa 0,325 seviyesine düşüyor [15]. Farklı mimarilerin kafa kafaya karşılaştırmasında da ResNet-50, EfficientNet-B0 ve DenseNet-121 birbirine yakın sonuç veriyor; asıl fark mimariden değil modaliteden geliyor ve dijital mamogramlar sentetik olanları geçiyor [14].

3.5 Sentez matrisi

Çalışma	Model / mimari	Veri	Metrik ve performans	Dış doğrulama
Amin ve ark. 2025 [1]	PRISMA sistematik derleme	1.051 kayıttan 287 makale	Görev ve eğilim analizi	Yok (derleme)
Fajrin ve Min 2025 [2]	PRISMA sistematik derleme	2018–2025 arası 50 çalışma	Yöntem ve kısıt analizi	Yok (derleme)
Chen ve ark. 2025 [3]	RSNA 2023 yarışması, 1.537 algoritma	10.830 tek meme muayenesi, 2 merkez (ABD, Avustralya)	En iyi algoritma: duyarlılık %48,6 · özgüllük %99,5 · PPV %64,6. Medyan: %27,6 · %98,7 · %36,9	Evet (gizli test kümesi)
Shia ve Ku 2024 [5]	YOLOv8-m	11.303 görüntü, 5.712 kadın	mAP50 0,921 · mAP50-95 0,709 · F1 0,82 · recall 0,796	Hayır

dondurulmuş [22]. Bu iki kısıt sonucun genellenebilirliğini sınırlıyor.

- LoMaR, Mirai'yi genişleterek keyfi sayıda longitudinal mamogramı transformer ile işliyor. Büyük ölçekli bir kümede, tarama-tespitli kanserler hariç tutulduğunda beşinci yılda Mirai'ye göre yaklaşık yüzde 10 ROCAUC üstünlük gösteriyor [23]. Kazanç kısa ufuklarda küçük, uzun ufuklarda büyük.
- TRINet, zaman-azalımlı dikkat, radyomik öznitelikler ve attention-based multiple instance learning birleşimi kullanıyor. EMBED test kümesinde 1–5 yıl AUC değerleri 0,851, 0,811, 0,796, 0,793 ve 0,789; ayrıca CSAW ile de değerlendirilmiş [24].
- VMRA-MaR, Vision-Mamba RNN ile iki taraflı asimetriyi birleştiriyor. CSAW-CC üzerinde 4 ve 5 yıllık ufuklarda ROCAUC 0,84 ve aynı noktalarda C-indeksi 0,82 bildiriyor; LoMaR'a göre farkın p değeri 0,061, yani sınırda [25]. Yüksek yoğunluklu alt grupta üstünlük daha belirgin.
- LongiMam, güncel muayeneye dört öncekini ekleyerek benzer bir yönü izliyor ve kazancın yoğun memeli, 55 yaş üstü ve yoğunluğu zamanla değişen kadınlarda yoğunlaştığını gösteriyor [26].

4.4 Dış doğrulama sınırları

Dış doğrulama bu kolun en kritik zayıflığı. Mirai, Meksikalı kadınlardan oluşan 3.110 hastalık bir kohortta (76 kanser) yalnızca C-indeksi 0,63 (yüzde 95 GA 0,6–0,7) elde ediyor; aynı çalışmada performans cihaz markasına göre de değişiyor ve IMS sistemlerinde 0,55'e iniyor [27]. Bu, geliştiricinin kendi kümelerindeki 0,76–0,81 aralığına göre belirgin bir düşüş.

Farklı bir modelin dış doğrulaması da benzer bir tablo veriyor. İsveç kohortlarında geliştirilen ProFound AI Risk 1.0, ABD'de 176 kanser ve 4.963 kontrolden oluşan bir kohortta AUC 0,68 (0,64–0,72) veriyor; beyaz kadınlarda 0,67, siyah kadınlarda 0,70 ve aradaki fark anlamlı değil [28]. Bu çalışma Mirai'yi değil iCAD'ın modelini doğruluyor ve literatürde zaman zaman karıştırılıyor.

Kol 2'nin gerçekçi tavanı, tek tek çalışmaların bildirdiği en yüksek değerlerden değil derlemelerden okunmalı. Schopf ve arkadaşları 16 çalışmada görüntü tabanlı modellerde medyan AUC 0,72, yoğunluk ve klinik risk araçlarında 0,61 buluyor [29]. Lowry ve arkadaşları 41 çalışmada medyan AUC'yi iki yıla kadar 0,71, üç ile dört yılda 0,72, beş yıl ve üzerinde 0,71 buluyor; indeks kanserler dahil edildiğinde 0,75, hariç tutulduğunda 0,68 [30]. Yani tekil çalışmalarda görülen 0,85 mertebesindeki değerler alanın ortalaması değil, üst ucu.

4.5 Sentez matrisi

Çalışma	Model / mimari	Veri	Metrik ve performans	Dış doğrulama
Yala ve ark. 2021 [17]	Mirai: ResNet-18 + transformer toplayıcı + additif hazard	MGH (eğitim); MGH, Karolinska, CGMH (test)	C-indeksi 0,76 (0,74–0,80) · 0,81 (0,79–0,82) · 0,79 (0,79–0,83)	Evet (2 ülke)
Yala ve ark. 2022 [18]	Mirai, çok kurumlu doğrulama	7 hastane, 5 ülke; 128.793 mamogram, 62.185 hasta	C-indeksi 0,75–0,84; Tyrer-Cuzick üzerinde üstünlük	Evet (7 hastane)
Donnelly ve ark. 2024 [20]	AsymMirai: yerel iki taraflı benzemezlilik	EMBED; 210.067 mamogram, 81.824 hasta	1/3/5 yıl AUC 0,79 / 0,68 / 0,66 (Mirai: 0,84 / 0,72 / 0,71)	Evet (EMBED)

Çalışma	Model / mimari	Veri	Metrik ve performans	Dış doğrulama
Dadsetan ve ark. 2022 [22]	LRP-NET: CNN + dondurulmuş VGG16 gövdesi	200 hastalık dengeli case-control, 4 ardışık muayene	Tek muayene modellerine üstün	Hayır (küçük, dengeli kohort)
Karaman ve ark. 2024 [23]	LoMaR: Mirai + keyfi uzunlukta longitudinal transformer	Büyük ölçekli tarama kümesi	5. yılda Mirai üzerinde ~%10 ROCAUC üstünlük (tarama-tespitli kanserler hariç)	Hayır (geliştirici bölgesi)
Yeoh ve ark. 2025 [24]	TRINet: zaman-azalımlı dikkat + radyomik + AMIL	EMBED (8.528 hasta), CSAW (8.723 hasta)	1–5 yıl AUC 0,851 / 0,811 / 0,796 / 0,793 / 0,789	Kısmi (2 küme)
Sun ve ark. 2025 [25]	VMRA-MaR: Vision-Mamba RNN + asimetri	CSAW-CC	4 ve 5 yıl ROCAUC 0,84; aynı noktalarda C-indeksi 0,82	Hayır (geliştirici bölgesi)
Avendano ve ark. 2024 [27]	Mirai, dış doğrulama	Meksika; 3.110 hasta, 76 kanser	C-indeksi 0,63 (0,6–0,7)	Evet
Gastounioti ve ark. 2022 [28]	ProFound AI Risk 1.0 (iCAD)	ABD; 176 kanser, 4.963 kontrol	AUC 0,68 (0,64–0,72); beyaz 0,67 · siyah 0,70	Evet
Schopf ve ark. 2024 [29]	PRISMA sistematik derleme	16 çalışma	Görüntü tabanlı modellerde medyan AUC 0,72; yoğunluk ve klinik araçlarda 0,61	Yok (derleme)
Lowry ve ark. 2026 [30]	PRISMA sistematik derleme	41 çalışma, tümü retrospektif	Medyan AUC 0,71 (≤ 2 yıl) · 0,72 (3–4 yıl) · 0,71 (≥ 5 yıl); kalibrasyon 41 çalışmanın 6 tanesinde	Yok (derleme)

5. Veri setleri

İki kolun veri ihtiyacı farklı. Kol 1 için lezyon seviyesinde anotasyon ve patoloji doğrulaması yeterli; Kol 2 için uzun takipli tarama kohortu zorunlu, çünkü etiket "ilerleyen yıllarda kanser çıktı mı" sorusunun cevabı.

Veri seti	Ölçek	Kaynak	Etiket	Kullanım
CBIS-DDSM [31]	3.103 taranmış film mamogram; 753 kalsifikasyon, 891 kitle vakası	ABD, DDSM türevi	ROI segmentasyonu, patoloji onaylı iyi ve kötü huylu ayrımı	Kol 1 — en sık kullanılan kıyaslama
INbreast [32]	410 FFDM görüntüsü, 115 vaka	Portekiz, tek merkez	BI-RADS ve uzman konturu; lezyonların çoğu biyopsi onaylı değil	Kol 1 — küçük ölçekli kıyaslama
VinDr-Mammo [33]	5.000 muayene, 20.000 görüntü	Vietnam, 2 hastane	Meme seviyesi BI-RADS, yoğunluk, lezyon bounding box; çift okuma ve üçüncü radyolog arbitrajı	Kol 1 — hemen indirilebilir public küme
RSNA 2023 [4]	10.830 tek meme muayenesi (değerlendirme kümesi)	ABD ve Avustralya	Patoloji ground truth; yaklaşık %2 pozitif oran	Kol 1 — gerçekçi tarama kıyaslaması
EMBED [34]	3,4 milyon görüntü, 110.000+ hasta, 60.000 anotasyonlu lezyon	ABD, Emory; siyah ve beyaz dengeli	2D, sentetik 2D ve DBT; BI-RADS ve patoloji	Her iki kol — risk modeli dış doğrulaması

Veri seti	Ölçek	Kaynak	Etiket	Kullanım
OPTIMAM (OMI-DB) [35]	2,5 milyondan fazla görüntü, 173.319 kadın; 9.690 tarama-tespitli ve 1.888 interval kanser	İngiltere NHS	ROI, klinik ve patoloji verisi, longitudinal takip	Her iki kol — erişim başvuru gerektirir
CSAW-CC [24, 25]	Karolinska tarama kohortu	İsveç	Uzun takipli tarama etiketleri	Kol 2 — longitudinal risk modelleri

INbreast'te lezyonların çoğu biyopsi ile doğrulanmamış; kötü huyluluk BI-RADS kategorisinden türetiliyor. Bu, küçük kümede bildirilen yüksek doğrulukların nasıl okunması gerektiğini doğrudan etkiliyor. RSNA kümesinde pozitif oranı yaklaşık yüzde 2 ve bu sınıf dengesizliği doğruluk metriğini kullanılamaz hale getiriyor.

6. Ana eğilimler, 2024–2026

1. Transformer benimsemesi. ViT, Swin ve DeiT ile tek görünümlü sınıflandırmadan çok görünümlü CC+MLO füzyonuna geçiş; hibrit CNN-transformer mimarileri [1, 9].
2. Temel modeller. Mammo-CLIP gibi vizyon-dil ve MammoDINO gibi self-supervised modeller etiketli veri ihtiyacını düşürüyor [10, 12].
3. Longitudinal modelleme. Risk tahmininde tek zaman noktasından temporal dizilere geçiş; LRP-NET, LoMaR, TRINet, VMRA-MaR ve LongiMam bu hattı oluşturuyor. Prior mamogramların katkısı özellikle dört ve beş yıllık ufuklarda belirginleşiyor [22–26].
4. Açıklanabilirlik. AsymMirai'nin iki taraflı benzemezliği ve Mammo-FACTOR'un cümle seviyesi öznitelik atfı, kara kutu skorunun yerine klinik olarak okunabilir bir sinyal koymayı hedefliyor [10, 20].
5. Çok modlu adaptasyon. Görüntü, radyoloji raporu metni ve klinik risk faktörlerinin birlikte kullanımı. Buradaki dikkat çekici bulgu, görüntü tabanlı modellere klinik veri eklemenin ayırım performansını genelde artırmaması; mamogramın kendisi zaten zengin prognostik sinyal taşıyor [29, 30].

7. Performans iddialarının değerlendirilmesi

Küçük, dengesiz ve ROI merkezli veri setlerinde bildirilen yüzde 99–100 doğruluk değerleri klinik olarak anlamlı değil. Bu değerler tipik olarak dört tuzaktan birini yansıtıyor. Veri sızıntısı, yani aynı hastanın görüntülerinin hem eğitim hem test kümesine karışması. Lezyon merkezli kırpmaya, yani tam mamogram taramasının asıl zorluğunun atlanması. Sınıf dengesizliğinin doğruluk metriğini şişirmesi. Ve dış doğrulama eksikliği.

Gerçekçi kıyaslama Kol 1 için RSNA 2023 yarışması. İki merkezden (ABD ve Avustralya) gelen 10.830 tek meme muayenesinden oluşan gizli test kümesinde 1.537 algoritma değerlendirildi. En iyi algoritma yüzde 48,6 duyarlılık, yüzde 99,5 özgüllük, yüzde 64,6 PPV ve yüzde 1,5 geri çağırma oranı verdi. Medyan algoritma ise yüzde 27,6 duyarlılık ve yüzde 98,7 özgüllükte kaldı. En iyi üç ve en iyi on algoritmanın ensemble'i duyarlılığı yüzde 60,7 ve yüzde 67,8'e çıkardı; en iyi on, Avrupa ve Avustralya'daki ortalama tarama radyoloğuna yakın performans gösterdi [3]. Yarışmanın sıralama metriği probabilistik F1 idi; kamuya açık lider tablosu skorları bu raporda doğrulanamadığı için burada yalnızca hakemli yayında raporlanan değerler veriliyor.

Kol 2 için gerçekçi aralık iki derlemeden okunuyor. Görüntü tabanlı modellerde medyan AUC 0,71–0,72, geleneksel yoğunluk ve klinik risk araçlarında yaklaşık 0,61 [29, 30]. Yani alanın gerçekçi tabanı 0,65, tavanı 0,85 civarında.

Pratik kural. ROI kırpma sınıflandırması ile tam mamogram tarama sınıflandırması asla karıştırılmamalı. Birincisinde lezyon zaten bulunmuş durumda, ikincisinde lezyonu bulmak görevin kendisi. Bunlar farklı zorluk seviyeleri ve doğrudan karşılaştırılmaz.

8. Öneriler ve karar eşikleri

Alana giriş için üç aşamalı bir sıra öneriliyor. Sıralamanın gerekçesi, her aşamanın bir sonrakinin değerlendirme zeminini kurması.

1. Temel oturtma. İki sistematik derleme okunarak alan haritalanır; Kol 1 için Amin ve arkadaşları [1], Kol 2 için Lowry ve arkadaşları [30]. Mirai deposu klonlanıp referans risk modeli bir örnek mamogramda çalıştırılır ve zihinsel taban çizgisi olarak sabitlenir [17].
2. Kıyaslama kurulumu. VinDr-Mammo ve RSNA 2023 üzerinde bir EfficientNet ya da ConvNeXt taban çizgisi kurulur. Metrik seti yalnızca doğruluk olmamalı: AUC, probabilistik F1, kalibrasyon ve sabit özgülükteki duyarlılık birlikte raporlanmalı. Papers with Code üzerinden CBIS-DDSM ve VinDr-Mammo sıralamaları izlenir.
3. İleri yöntemler. Kol 1'de çok görünümlü transformer [9] ve temel model ince ayarı [10], Kol 2'de longitudinal modeller [23, 24] denenir. EMBED erişimi risk tahmini deneyleri için kritik [34].

Karar eşikleri. Bir tespit ya da sınıflandırma modelini umut verici saymak için tek veri setindeki yüzde 99 doğruluk yeterli değil; en az bir harici kohortta gerçekçi metrik aranmalı. Bir risk modelini klinik potansiyeli var saymak için en az bir harici popülasyonda AUC 0,75 ve üzeri ile birlikte kalibrasyon değerlendirmesi olmalı. Lowry derlemesinde 41 çalışmanın yalnızca altısı kalibrasyon raporlamış [30]; bu boşluk bir farklılaşma fırsatı. Dış doğrulama yoksa veya veri seti yaklaşık 1.000 hastadan azsa, iddia ön sonuç olarak işaretlenmeli.

9. Sınırlılıklar

- Bazı performans değerleri hakemli olmayan, küçük veya ROI merkezli kaynaklardan geliyor ve klinik geçerlilik göstermiyor. Bu rapor bu tür değerleri metne almadı.
- Amin ve arkadaşlarının derlemesinde görev bazlı toplam sayılar ağırlıklı olarak şekiller ve ek tablolarda sunulmuş; ana metinde konsolide bir sayısal doğruluk aralığı bulunmuyor [1]. Bu nedenle Kol 1 için tek bir alan ortalaması verilemiyor.
- TRINet, LoMaR, VMRA-MaR ve LongiMam gibi longitudinal modeller henüz geliştirici dışı bağımsız dış doğrulamadan geçmedi. Bildirilen AUC değerleri geliştiricinin kendi test bölmelerinden geliyor ve iyimser olabilir [23–26].
- Lowry derlemesindeki 41 çalışmanın tümü retrospektif [30]. Alanın hiçbir modeli için olgun prospektif klinik fayda kanıtı yok.
- Veri çeşitliliği kritik bir kör nokta. Risk çalışmaları ağırlıklı olarak beyaz, Hispanik olmayan popülasyonları temsil ediyor [30]. Belirli bir popülasyona hizmet edecek bir sistem için hedef popülasyonda yerel doğrulama vazgeçilmez.
- Rapor 2020–2026 penceresiyle ve derin öğrenme tabanlı yaklaşımlarla sınırlı. Klasik radyomik ve el yapımı öznetelik çalışmaları kapsam dışında.

10. Sonuç

İki kol ayrı tutulduğunda tablo netleşiyor. Kol 1'de mimari ilerlemesi hızlı ama gerçek tarama koşullarındaki performans, yayınlanan tekil doğruluk değerlerinin çok altında. Yarışma verisi bunu doğrudan gösteriyor: 1.537 algoritmanın medyanı yüzde 27,6 duyarlılıkta, en iyisi yüzde 48,6'da [3]. Kol 2'de referans model kurumlar arası tutarlılığını koruyor ama farklı popülasyonlarda gerileme belirgin ve alanın gerçekçi ayırım gücü medyan AUC 0,71–0,72 civarında [17, 27, 29, 30].

İki kolun ortak eksiği aynı ve teknik değil metodolojik. Dış doğrulama az, kalibrasyon neredeyse hiç yok, prospektif kanıt yok. Bu, alandaki bir sonraki değerli katkının daha büyük bir model olmayabileceğini gösteriyor. Harici bir kohortta kalibrasyonu da raporlanan mütevazı bir model, tek merkezde parlayan bir modelden daha fazla şey söylüyor.

Kaynaklar

1. Amin A, Acharya U D, Koteshwara P, Siddalingaswamy PC, Mathew S (2025). A systematic literature review on mammography: deep learning techniques for breast cancer detection with global and Asian perspectives. BMC Cancer, 25, 1627. [10.1186/s12885-025-14876-5](https://doi.org/10.1186/s12885-025-14876-5)
2. Fajrin HR, Min SD (2025). From machine learning to ensemble approaches: a systematic review of mammogram classification methods. Diagnostics, 15(22), 2829. [10.3390/diagnostics15222829](https://doi.org/10.3390/diagnostics15222829)
3. Chen Y, vd. (2025). Performance of algorithms submitted in the 2023 RSNA screening mammography breast cancer detection AI challenge. Radiology. [10.1148/radiol.241447](https://doi.org/10.1148/radiol.241447) — bölüm 7'deki duyarlılık, özgüllük ve PPV değerleri bu çalışmadan.
4. Open-source dataset for the RSNA screening mammography cancer detection challenge (2025). Radiology: Artificial Intelligence. [10.1148/ryai.250375](https://doi.org/10.1148/ryai.250375) — veri seti [Kaggle](https://www.kaggle.com/datasets/rsna-breast-cancer-detection) ve [GitHub wiki](https://github.com/rsna-breast-cancer-detection) üzerinden erişilebilir.
5. Shia W-C, Ku T-H (2024). Enhancing microcalcification detection in mammography with YOLO-v8: performance and clinical implications. Diagnostics, 14(24), 2875. [10.3390/diagnostics14242875](https://doi.org/10.3390/diagnostics14242875)
6. Ho P-S, Tsai H-Y, Liu I, Lee Y-Y, Chan S-W (2025). Improving YOLO-based breast mass detection with transfer learning pretraining on the OPTIMAM Mammography Image Database. Computers in Biology and Medicine. [sciencedirect.com/science/article/abs/pii/S0010482525009321](https://www.sciencedirect.com/science/article/abs/pii/S0010482525009321)
7. Agarwal R, Diaz O, Lladó X, Yap MH, Martí R (2019). Automatic mass detection in mammograms using deep convolutional neural networks. Journal of Medical Imaging, 6(3), 031409. [10.1117/1.JMI.6.3.031409](https://doi.org/10.1117/1.JMI.6.3.031409) — INbreast üzerinde 0,3 FP/görüntüde yüzde 92 duyarlılık sonucunun asıl kaynağı.
8. Famouri S, Morra L, Mangia L, Lamberti F (2021). Breast mass detection with Faster R-CNN: on the feasibility of learning from noisy annotations. IEEE Access. [arXiv:2104.12218](https://arxiv.org/abs/2104.12218) — INbreast sonucunu yalnızca alınıyor; kendi deneyleri CBIS-DDSM üzerinde.
9. Sarker S, Sarker P, Bebis G, Tavakkoli A (2024). MV-Swin-T: mammogram classification with multi-view Swin transformer. IEEE International Symposium on Biomedical Imaging (ISBI). [arXiv:2402.16298](https://arxiv.org/abs/2402.16298)
10. Ghosh S, Poynton CB, Visweswaran S, Batmanghelich K (2024). Mammo-CLIP: a vision language foundation model to enhance data efficiency and robustness in mammography. MICCAI 2024. [arXiv:2405.12255](https://arxiv.org/abs/2405.12255) — [MICCAI bildiri sayfası](#)
11. Yang S, Zhang C, Liang X, vd. (2025). Mammo-Clustering: context clustering based multi-view tri-level information fusion for lesion location and classification in mammography. [arXiv:2507.18642](https://arxiv.org/abs/2507.18642)
12. MammoDINO: anatomically aware self-supervision for mammographic images (2025). [arXiv:2510.11883](https://arxiv.org/abs/2510.11883) — [GE HealthCare tanıtım sayfası](#)

13. Khara G, vd. (2024). Generalisable deep learning method for mammographic density prediction across imaging techniques and self-reported race. *Communications Medicine*, 4. [10.1038/s43856-024-00446-6](https://doi.org/10.1038/s43856-024-00446-6)
14. Anant K, Hernández López J, Cui J, Das Gupta S, Bennett DL, Gastounioti A (2026). Head-to-head comparisons of breast density assessment models using deep learning on digital and synthetic mammograms. *Journal of Medical Imaging*, 13(2), 024503. [10.1117/1.JMI.13.2.024503](https://doi.org/10.1117/1.JMI.13.2.024503)
15. Abrantes J, Bento e Silva MJN, Meneses JP, Oliveira C, Calisto FMGF, Filice RW (2023). External validation of a deep learning model for breast density classification. ECR 2023 poster, C-16014. epos.myesr.org/poster/esr/ecr2023/C-16014 — hakemli yayın değil, poster.
16. RSNA (2025). AI challenge models can independently interpret mammograms. rsna.org — kaynak 3'ün kurum duyurusu; sayısal değerler için 3 kullanılmalı.
17. Yala A, Mikhael PG, Strand F, vd. (2021). Toward robust mammography-based models for breast cancer risk. *Science Translational Medicine*, 13(578), eaba4373. [10.1126/scitranslmed.aba4373](https://doi.org/10.1126/scitranslmed.aba4373)
18. Yala A, Mikhael PG, Strand F, vd. (2022). Multi-institutional validation of a mammography-based breast cancer risk model. *Journal of Clinical Oncology*, 40(16), 1732–1740. [10.1200/JCO.21.01337](https://doi.org/10.1200/JCO.21.01337)
19. Mirai model deposu. github.com/yala/Mirai
20. Donnelly J, Moffett L, Barnett AJ, Trivedi H, Schwartz F, Lo J, Rudin C (2024). AsymMirai: interpretable mammography-based deep learning model for 1–5-year breast cancer risk prediction. *Radiology*, 310(3), e232780. [10.1148/radiol.232780](https://doi.org/10.1148/radiol.232780)
21. RSNA (2024). Deep learning for predicting breast cancer. rsna.org — kaynak 20'nin kurum duyurusu.
22. Dadsetan S, Arefan D, Berg WA, Zuley ML, Sumkin JH, Wu S (2022). Deep learning of longitudinal mammogram examinations for breast cancer risk prediction. *Pattern Recognition*, 132, 108919. [10.1016/j.patcog.2022.108919](https://doi.org/10.1016/j.patcog.2022.108919)
23. Karaman BK, Dodelzon K, Akar GB, Sabuncu MR (2024). Longitudinal mammogram risk prediction. MICCAI 2024. [arXiv:2404.19083](https://arxiv.org/abs/2404.19083) — MICCAI bildiri sayfası
24. Yeoh HH, Strand F, Phan R, Rahmat K, Tan M (2025). A new time-decay radiomics integrated network (TRINet) for breast cancer risk prediction. *Medical Image Analysis*. [sciencedirect.com/science/article/pii/S1361841525003755](https://www.sciencedirect.com/science/article/pii/S1361841525003755) — [arXiv:2412.03081](https://arxiv.org/abs/2412.03081)
25. Sun Z, Thrun S, Kampffmeyer M (2025). VMRA-MaR: an asymmetry-aware temporal framework for longitudinal breast cancer risk prediction. [arXiv:2506.17412](https://arxiv.org/abs/2506.17412)
26. Rakez M, Louis T, Guillaumin J, Chamming's F, Fillard P, Amadeo B, Rondeau V (2025). The LongiMam model for improved breast cancer risk prediction using longitudinal mammograms. [arXiv:2509.21383](https://arxiv.org/abs/2509.21383)
27. Avendano D, Marino MA, Bosques-Palomo BA, vd. (2024). Validation of the Mirai model for predicting breast cancer risk in Mexican women. *Insights into Imaging*, 15, 244. [10.1186/s13244-024-01808-3](https://doi.org/10.1186/s13244-024-01808-3)
28. Gastounioti A, Eriksson M, Cohen EA, vd. (2022). External validation of a mammography-derived AI-based risk model in a U.S. breast cancer screening cohort of white and black women. *Cancers*, 14(19), 4803. [10.3390/cancers14194803](https://doi.org/10.3390/cancers14194803) — Mirai'yi değil iCAD ProFound AI Risk 1.0 modelini doğruluyor.
29. Schopf CM, vd. (2024). Artificial intelligence-driven mammography-based future breast cancer risk prediction: a systematic review. *Journal of the American College of Radiology*, 21(2), 319–328. [10.1016/j.jacr.2023.10.018](https://doi.org/10.1016/j.jacr.2023.10.018)
30. Lowry KP, Jeong HE, Kim KH, Hughes KS, Lee CI, Yala A, Kerlikowske K, Vachon CM (2026). Current state of mammography-based artificial intelligence for future breast cancer risk prediction: a systematic review. *JNCI: Journal of the National Cancer Institute*, 118(3), 392–403. [10.1093/jnci/djag002](https://doi.org/10.1093/jnci/djag002)
31. Lee RS, Gimenez F, Hoogi A, Miyake KK, Gorovoy M, Rubin DL (2017). A curated mammography data set for use in computer-aided detection and diagnosis research. *Scientific Data*, 4, 170177. [10.1038/sdata.2017.177](https://doi.org/10.1038/sdata.2017.177) — CBIS-DDSM dağıtım sayfası

32. Moreira IC, Amaral I, Domingues I, Cardoso A, Cardoso MJ, Cardoso JS (2012). INbreast: toward a full-field digital mammographic database. *Academic Radiology*, 19(2), 236–248. [10.1016/j.acra.2011.09.014](https://doi.org/10.1016/j.acra.2011.09.014)
33. Nguyen HT, vd. (2023). VinDr-Mammo: a large-scale benchmark dataset for computer-aided diagnosis in full-field digital mammography. *Scientific Data*, 10, 277. [10.1038/s41597-023-02100-7](https://doi.org/10.1038/s41597-023-02100-7) — [PhysioNet dağıtımı](#)
34. Jeong JJ, vd. (2023). The EMory BrEast imaging Dataset (EMBED): a racially diverse, granular dataset of 3.4 million screening and diagnostic mammographic images. *Radiology: Artificial Intelligence*, 5(1), e220047. [10.1148/ryai.220047](https://doi.org/10.1148/ryai.220047) — [AWS Open Data kaydı](#)
35. Halling-Brown MD, Warren LM, Ward D, vd. (2021). OPTIMAM mammography image database: a large-scale resource of mammography images and clinical data. *Radiology: Artificial Intelligence*, 3(1), e200103. [10.1148/ryai.2020200103](https://doi.org/10.1148/ryai.2020200103) — [arXiv:2004.04742](https://arxiv.org/abs/2004.04742)