

Mamografide Kitle (Mass) Lezyon Tespiti

Sonuç Raporu

1. Amaç ve Kapsam

Bu çalışmanın amacı, mamografi görüntülerinde kitle (mass) lezyonlarının nesne tespiti ile otomatik olarak bulunmasında öne çıkan üç farklı derin öğrenme mimarisini kendi veri setimizde yeniden üretmekti. Sırasıyla YOLO11, YOLO26 ve RF-DETR eğitildi; elde edilen sonuçlar hem kendi aralarında hem de mimarilerin kaynak duyurularında bildirilen genel performansla karşılaştırıldı.

Veri seti tek sınıf (`mass`), YOLO formatında etiketli, toplam 3340 görüntü ve 4021 kutu içeriyor.

Bölme	Görüntü	Kutu
Eğitim	2671	3203
Doğrulama	333	418
Test	336	400

Görüntülere, meme dokusunu arka plandan ayırıp kırpan bir ön işleme uygulandı. Bu işlem, kutu alanı görüntünün %1'inden küçük olan "küçük nesne" oranını %72'den %39.3'e düşürdü. Üç model de aynı kırpılmış veriyle, aynı sınıf tanımı ve aynı erken durdurma kuralıyla (patience=5) eğitildi; aradaki fark yalnızca mimariden ve mimariye özgü optimizasyon kararlarından kaynaklanıyor.

2. Modellerde Kullanılan Yöntemler

Bu bölümde üç mimarinin kendi kaynaklarındaki tasarımı kısaca özetleniyor. Kendi veri setindeki uygulama detayları bir sonraki bölümde ele alınıyor.

2.1 YOLO11 (Ultralytics)

Ultralytics'in 2024'te yayımladığı, tek aşamalı ve hızlı çalışan bir nesne tespit modeli. Hız ve doğruluk dengesi iyi olan "s" (small) boyutu tercih edildi.

2.2 YOLO26 (Ultralytics)

Ultralytics'in 2025'te tanıttığı daha yeni bir model. YOLO11'den farklı olarak, tespit sonrası ayrı bir "gereksiz kutuları eleme" adımına ihtiyaç duymuyor; bu da modeli biraz daha basit ve hızlı hale getiriyor.

2.3 RF-DETR (Roboflow)

Roboflow tarafından geliştirilen, YOLO'dan farklı bir yapıya (transformer tabanlı) sahip bir model. Roboflow'a göre RF-DETR, gerçek zamanlı çalışan modeller arasında COCO veri setinde en

yüksek doğruluğa ulaşanlardan biri. Bu çalışmada modelin küçük ("Small") versiyonu kullanıldı.

2.4 Literatürde Mamografide Kitle Tespiti


Aşağıdaki tablo, aynı görevi (mamografide kitle tespiti) farklı yaygın veri setlerinde (VinDr-Mammo, CBIS-DDSM, INbreast) ele alan güncel çalışmaların sonuçlarıyla bu çalışmanın sonuçlarını bir arada gösteriyor.

Çalışma	Veri seti	Model	Precision	Recall	mAP@50	mAP@50-95
Samadi vd. (2026)	VinDr-Mammo	YOLOv11n + CLAHE/dikkat	0.7024	0.6801	0.6828	0.4082
Manolakis vd. (2025)	CBIS-DDSM	YOLOv5n	—	—	0.5030	0.2010
Manolakis vd. (2025)	INbreast (dış test)	YOLOv5n	—	—	0.6820	0.3150
Bu çalışma	VinDr-Mammo + Teknofest (kırpılmış)	YOLO11s (SGD)	0.7802	0.7000	0.7561	0.4121
Bu çalışma	VinDr-Mammo + Teknofest (kırpılmış)	RF-DETR-S	0.6163	0.8150	0.7551	0.4109
Bu çalışma	VinDr-Mammo + Teknofest (kırpılmış)	YOLO26s (SGD)	0.7011	0.6392	0.6914	0.3686

Veri setleri ve ön işleme farklı olduğundan bu tam anlamıyla kontrollü bir kıyaslama değil. Yine de bu çalışmanın YOLO11s sonucu (mAP@50=0.7561), aynı VinDr-Mammo ailesinde YOLO11 kullanan bir literatür çalışmasının sonucunun (mAP@50=0.6828) belirgin şekilde üzerinde. Farklı veri bölmeleri ve ek ön işleme adımları (CLAHE, dikkat mekanizması) da devrede olduğundan kesin bir nedensellik kurulamaz; yine de bu fark, kırpma ön işleminin ve SGD'ye geçişin sonuca katkıda bulunmuş olabileceğini düşündürmektedir.

3. Kendi Veri Setimizdeki Uygulama

Ön işleme sırasında görüntüler gri tonlamalı okundu; sabit bir eşik (10, Otsu değil) ile arka plan ayrıldı; morfolojik açma (9×9 disk) ile kenar yazıları ve küçük artefaktlar temizlendi; en büyük bağlı bileşen meme dokusu olarak seçilip %5 kenar payıyla kırıldı. YOLO11 ve YOLO26 bu veriyi doğrudan YOLO formatında kullandı; RF-DETR için aynı veri, görüntülere dokunmadan COCO JSON formatına dönüştürüldü.



Şekil 1. Kırpma ön işleme hattı. Soldan sağa: ham görüntü → sabit eşikle (10) ikili maske → en büyük bağlı bileşen (meme dokusu) → %5 kenar paylı kırpma kutusu → final kırpılmış görüntü (yeşil kutu: yeniden hesaplanmış etiket).

Parametre	YOLO11s	YOLO26s	RF-DETR-S
Ön eğitim	COCO	COCO	DINOv2 + COCO
Görüntü boyutu	1024	1024	model varsayılanı
Optimizer	SGD, lr=0.001	SGD, lr=0.001	AdamW, lr=1e-4
Efektif batch	8	8	16 (4×4)
Erken durdurma	patience=5	patience=5	patience=5
Seed	42	42	42

4. Yöntem Bazlı Sonuçlar


Aşağıdaki üç alt bölüm aynı düzeni izliyor. Önce ölçüm tablosu, sonra eğitim eğrileri, sonra confusion matrix ve mümkünse Grad-CAM örneği yer alıyor.

4.1 YOLO11s Sonuçları


Tek adımda bulunmuş bir sonuç değil; sırayla üç deney kuruldu. İlk olarak kırpmasız veriyle bir referans (Deney 1) eğitildi. Ardından kırpılmış veriyle, AdamW optimizer'ıyla (Deney 2a/2b) tekrar eğitildi; patience=5 ve patience=10 birebir aynı sonucu verdi, yani erken durdurma sınırlayıcı değildi. Sonuç kırpmasız referansın hafifçe altında kalınca, tek değişken olarak optimizer SGD'ye çevrildi (Deney 2e) ve bu, projedeki en iyi sonucu verdi.

Deney	Ayar	mAP@50	mAP@50-95	Precision	Recall	F1
Deney 1 (kırpmasız)	optimizer=auto	0.6928	0.3820	0.7475	0.6365	0.6876
Deney 2a/2b (kırpılmış)	AdamW, lr0=0.001, patience=5/10	0.6901	0.3669	0.6823	0.6325	0.6565
Deney 2e (kırpılmış) — final	SGD, lr0=0.001	0.7561	0.4121	0.7802	0.7000	0.7379


En iyi sonucu veren kurulum (Deney 2e): `optimizer='SGD', lr0=0.001, cos_lr=True`. Eğitim 19 epoch sürdü (0-18); train/val loss paralel düştü, overfitting işareti yok.



Şekil 2. YOLO11s eğitim eğrileri (19 epoch).



Şekil 3. Confusion Matrix (Test, IoU=0.5). TP=302, FP=129, FN=98.



Şekil 4. Grad-CAM örnekleri (P3 katmanı, dokuya maskelenmiş).


Kaynakla karşılaştırma: Ultralytics'in genel COCO rakamı (~47 mAP50-95, 80 sınıf) ile elde edilen sonuç (mAP50-95=0.412) doğrudan kıyaslanamaz, çünkü görevler farklı. Projenin kendi kırpmasız YOLO11s referansının (mAP@50=0.6928) belirgin şekilde üzerinde.

4.2 YOLO26s Sonuçları


YOLO26'da da üç deney sırayla kuruldu. İlk kurulum (Deney 2c), YOLO11 için doğrulanmış ayarların (AdamW, imgsz=1024) doğrudan aktarılmasıydı; YOLO11'in altında kaldı. Küçük nesnelere daha fazla piksel ayırmak için çözünürlük artırıldı (Deney 2d, imgsz=1280) ama sonuç beklenenin tersine daha kötü çıktı. Son olarak YOLO11'de işe yarayan değişiklik (SGD, lr0=0.001) burada da denendi (Deney 2f) ve en iyi YOLO26 sonucunu verdi; yine de YOLO11'in gerisinde kaldı. Eğitim eğrisi incelendiğinde val loss düz bir platoda kalıyor, yani overfitting yok; ancak mAP@50 eğrisi eğitim durduğunda (epoch 16) hâlâ hafif yükseliş eğilimindeydi, bu da modelin patience=5 tetiklenmeden önce tam potansiyeline ulaşamamış olabileceğini düşündürüyor.

Deney	Ayar	mAP@50	mAP@50-95	Precision	Recall	F1
Deney 2c	AdamW, imgsz=1024	0.6494	0.3483	0.6551	0.6316	0.6432
Deney 2d	AdamW, imgsz=1280	0.6220	0.3367	0.6772	0.5875	0.6292
Deney 2f — final	SGD, lr0=0.001, imgsz=1024	0.6914	0.3686	0.7011	0.6392	0.6687


En iyi sonucu veren kurulum (Deney 2f): YOLO11 ile birebir aynı optimizasyon kararları (SGD, lr0=0.001) YOLO26'nın NMS-free mimarisine uygulandı. Eğitim 17 epoch sürdü (0-16).



Şekil 5. YOLO26s eğitim eğrileri (17 epoch).



Şekil 6. Confusion Matrix (Test, IoU=0.5). $TP=253$, $FP=90$, $FN=147$.




Şekil 7. Grad-CAM örnekleri (one2one_cv3 dalından).


Kaynakla karşılaştırma: YOLO26 için doğrulanmış bir COCO referans rakamı bulunamadı. Kendi veri setimizde, aynı optimizasyon kararlarıyla YOLO11'in belirgin biçimde altında kaldı (mAP@50'de -6.5 puan).

4.3 RF-DETR-Small Sonuları


YOLO11/YOLO26'nın aksine RF-DETR'de bir hiperparametre ablasyonu yapılmadı; tek bir kurulum (Deney 3, kütüphane varsayılanlarına yakın ayarlar) eğitildi ve doğrudan bu sonuç alındı. DINOv2 ön-eğitimli omurga, efektif batch 16, lr=1e-4 kullanıldı. Eğitim 15 epoch sürdü (0-14). En iyi doğrulama sonucu epoch 9'da görüldü, ardından patience=5 boyunca iyileşme olmayınca durdu; bu, YOLO'ya göre belirgin şekilde daha hızlı bir yakınsama. Test sonuçları: mAP@50=0.7551, mAP@50-95=0.4109, Precision=0.6163, Recall=0.8150, F1=0.7018. Eğitim eğrisinde dikkat edilmesi gereken bir nokta var: val loss epoch 8'e kadar düşüyor, ardından epoch 14'e kadar tekrar yükseliyor, train loss ise düşmeye devam ediyor; bu, hafif bir overfitting başlangıcına işaret ediyor. Ancak raporlanan sonuçlar en son epoch'tan değil, val loss henüz yükselmeden önceki en iyi kontrol noktasından (`checkpoint_best_total.pth`, ~epoch 8-9) alındığından, bu etkidenden bağımsız.



Şekil 8. RF-DETR-S eğitim eğrileri (15 epoch).



Şekil 9. Confusion Matrix (Test, IoU=0.5). TP=326, FP=203, FN=74.



Şekil 10. Grad-CAM örnekleri (DINOv2 omurga çıktısı, yüzdelik-dilim tabanlı normalizasyon).

RF-DETR'nin transformer/DINOv2 tabanlı mimarisi YOLO'daki katman-hook yaklaşımını doğrudan desteklemediği için ayrı bir yöntem gerekti: sınıf logit'i, omurganın döndürdüğü özellik haritasına göre geri yayılıyor. Standart ReLU-tabanlı normalizasyon bu mimaride boş harita

ürettiğinden (LayerNorm istatistikleri, ReLU sonrası her yerde negatif çıkıyor), ReLU atlanıp iç bölgeden hesaplanan yüzdelik-dilim (70.-99.) tabanlı kırpma kullanıldı.

Kaynakla karşılaştırma: Roboflow'un RF-DETR-Base için bildirdiği "COCO'da 60 mAP" iddiası 80 sınıflı genel bir görev için, elde edilen sonuçla (mAP50-95=0.411) doğrudan kıyaslanamaz. Az epoch'ta güçlü sonuç özelliği burada da doğrulandı.

5. Üç Yöntemin Kendi Aralarında Karşılaştırılması

Model	mAP@50	mAP@50-95	Precision	Recall	F1
YOLO11s (SGD)	0.7561	0.4121	0.7802	0.7000	0.7379
RF-DETR-S	0.7551	0.4109	0.6163	0.8150	0.7018
YOLO26s (SGD)	0.6914	0.3686	0.7011	0.6392	0.6687

Model	TP	FP	FN	Profil
YOLO11s	302	129	98	Dengeli
RF-DETR-S	326	203	74	Recall-ağırlıklı
YOLO26s	253	90	147	Precision-ağırlıklı, düşük recall

mAP'te YOLO11s ve RF-DETR-S neredeyse eşit olsa da (fark 0.001), altta yatan hata örüntüleri tamamen farklı. YOLO11s dengeli ve hassasiyet-ağırlıklı; RF-DETR ise belirgin şekilde recall-ağırlıklı. Daha fazla gerçek lezyonu yakalıyor ama iki katı kadar yanlış alarm üretiyor. YOLO26 ise ikisinin de gerisinde. Tıbbi tarama bağlamında yüksek recall genellikle yüksek precision'dan daha değerli kabul edilir; bu çerçevede RF-DETR'nin profili, ham F1 skorunda geride kalmasına rağmen kullanım amacına göre tercih edilebilir olabilir.

6. Sonuç ve Değerlendirme

Üç mimari de aynı kırpılmış veri setinde, aynı erken durdurma kuralıyla eğitildi. En yüksek mAP'i YOLO11s (SGD ile) verdi, RF-DETR-S ona pratik olarak eşit bir sonuca çok daha az epoch'ta ulaştı. Bu sonuç, DINOv2 ön eğitiminin transfer öğrenme sürecindeki yakınsama hızına olumlu katkı sağlayabileceğini göstermektedir. YOLO26, aynı optimizasyon reçetesiyle beklenmedik şekilde iki modelin de gerisinde kaldı; ayrıca YOLO26'ya özgü bir hiperparametre araması yapılmadığı bir sınırlama.

Bu çalışmanın en önemli bulgularından biri, mAP'in tek başına yeterli olmadığıdır. YOLO11s ve RF-DETR-S'nin neredeyse eşit mAP'i, tamamen farklı precision/recall dengeleri arkasında saklanıyor. Model seçimi bu nedenle yalnızca tek bir sayıya değil, kullanım senaryosunun hata toleransına bağlı olmalı.

Eğitim eğrileri overfitting açısından ayrıca incelendi. YOLO11s ve YOLO26s'de val loss düz bir platoda kalıyor, artmıyor; overfitting işareti yok. RF-DETR-S'de ise val loss eğitimin son üçte birinde tekrar yükseliyor, hafif bir overfitting başlangıcına işaret ediyor; ancak değerlendirme bu

noktadan önceki en iyi kontrol noktasıyla yapıldığından raporlanan sonuçlar bundan etkilenmiyor. Ayrıca YOLO26s'nin mAP eğrisi eğitim durduğunda hâlâ yükseliş eğilimindeydi, bu da erken durdurmanın bu model için tam potansiyele ulaşmadan devreye girmiş olabileceğini düşündürüyor.

Bazı sınırlamalar da var. Grad-CAM görselleri, tek bir hedef hücreden (tespit/gerçek kutu merkezi) geri yayılan, eleman-bazlı gradyan×aktivasyon ile hesaplanan noktasal bir yaklaşım; modelin tüm görüntü genelindeki dikkat dağılımını değil, seçilen tek tespit için nedensel katkıyı gösteriyor. "Kaçırılan" örneklerde ısı haritasının o bölgeye yine de lokalize olabilmesi (eşik-altı ama sıfır olmayan bir sinyal nedeniyle) modelin gerçek güven skoruyla birlikte yorumlanmalı; bu yüzden panel başlıklarına skor eklendi. Üç model de tek bir eşik değerinde (conf=0.25) değerlendirildi; RF-DETR'nin precision/recall dengesi eşik ayarıyla kaydırılabilir, bu rapor kapsamında denenmedi.