

Mamografide Meme Yoğunluğu (Breast Density) Segmentasyonu

Altı derin öğrenme modelinin karşılaştırmalı sonuç raporu

1. Amaç ve Veri

Mamografi görüntülerinde yoğun (dens) meme dokusunun ikili segmentasyonu için dört mimari (U-Net, U-Net++, DeepLabV3+, SegFormer) ve üç encoder ailesi (ResNet, EfficientNet, Mix Transformer) birleştirilerek altı model eğitildi. Veri bölünmesi, ön işleme, augmentation stratejisi, kayıp fonksiyonu ve genel optimizasyon yaklaşımı tüm modellerde sabit tutulmuş, mimarilerin bellek ve optimizasyon gereksinimleri doğrultusunda batch size ve öğrenme oranı gibi model-spesifik hiperparametreler kontrollü biçimde belirlenmiştir.

Veri kaynağı Behravan vd. (2024) tarafından yayımlanan *Mammogram Density Assessment Dataset*'tir. Orijinal set VinDr-Mammo'dan seçilmiş 745 görüntüden oluşur (596 eğitim / 149 test), JPG, 2800×3518 maskeler uzman radyolog tarafından işaretlenmiş, hem meme alanını hem dens dokuyu kapsamaktadır. Bu çalışmada kullanılan sürüm, bu setin NIfTI'ye dönüştürülmüş ve 512×512'ye yeniden boyutlandırılmış 536 vakalık alt kümesidir.

Bölme	Vaka	Klasör
Eğitim	447	imagesTr / labelsTr
Doğrulama	89	imagesVal / labelsVal

Görüntüler tek kanallı float64, piksel aralığı 0-238, maskeler ikili. Bölme klasör bazlıdır ve değiştirilmemiştir. Yoğunluk yüzdesi JSON dosyaları segmentasyon hedefi olarak kullanılmamış, yalnızca vaka görsellerinde bağlam bilgisi olarak gösterilmiştir. Kullanılan sürümde meme alanı maskesi bulunmadığından "dens alan / meme alanı" oranı doğrudan hesaplanamamıştır.

2. Yöntem

2.1 Veri hattı

Her görüntü kendi içinde min-maks normalizasyonu ile [0, 1] aralığına çekildi (ham piksel aralığı dosyadan dosyaya değiştiğinden sabit global maksimum varsayılmadı), üç kanala kopyalandı ve ImageNet istatistikleriyle normalize edildi.

Eğitim augmentasyonu: yatay çevirme ($p=0,5$), dikey çevirme ($p=0,3$), $\pm 15^\circ$ döndürme ($p=0,5$), parlaklık/kontrast ($\pm 0,15$, $p=0,5$), elastik deformasyon ($p=0,2$), CoarseDropout ($p=0,2$). Görev doku oranı ölçümüne dayandığından agresif kırpma/yakınlaştırma kullanılmadı. Doğulamada yalnızca yeniden boyutlandırma ve normalizasyon uygulandı.

2.2 Eğitim yapılandırması

Loss: Dice + BCE. Metrikler görüntü başına hesaplanıp ortalandı. İkili segmentasyonda F1 tanım gereği Dice'a eşittir. AMP, gradyan kırpma ($\text{max_norm}=1,0$), 3 epoch doğrusal warmup ve ReduceLROnPlateau (val loss 3

epoch iyileşmezse $\times 0,5$, min 1×10^{-7}) kullanıldı. Optimizer AdamW (weight decay 1×10^{-4}), görüntü 512×512 , seed 42.

Model	Batch	LR (encoder / decoder)	Maks. epoch	Patience
U-Net + ResNet34	16	$5 \times 10^{-5} / 2,5 \times 10^{-4}$	70	15
U-Net + EfficientNet-B0	16	$5 \times 10^{-5} / 2,5 \times 10^{-4}$	70	15
U-Net++ + ResNet34	12	$5 \times 10^{-5} / 2,5 \times 10^{-4}$	70	15
DeepLabV3+ + ResNet50	8	$1 \times 10^{-4} / 5 \times 10^{-4}$	70	15
DeepLabV3+ + EfficientNet-B3	8	$1 \times 10^{-4} / 5 \times 10^{-4}$	70	15
SegFormer-B2	8	1×10^{-4} (tek LR)	70	15

Epoch sınırı başlangıçta ağır mimariler için 60/12 olarak planlanmıştı. İlk üç modelin zirvelerini epoch 50 ve 54'te yapması üzerine, 60 tavanının bazı modelleri erken kesme riski taşıdığı görüldü ve bütçe altı modelde 70/15'e eşitlendi. Değişiklik dördüncü model eğitime başlanmadan uygulandı.

Doğrulama setinden sabit seed ile seçilen beş görsel karşılaştırma vakası tüm modellerde aynıdır.

2.3 Tespit edilen iki hata

İlk denemelerde train loss düzgün azalırken doğrulama Dice'ı epoch'lar arasında 0,0002-0,56 bandında sıçırıyordu. İki ayrı hata tespit edildi, her ikisi de hata vermeden çalışıp sonucu bozduğu için belgelenmiştir.

(a) Çift normalizasyon. Görüntü veri kümesi içinde [0, 1] aralığına çekildikten sonra Normalize dönüşümü varsayılan max_pixel_value=255 ile bir kez daha bölüyordu. Dinamik aralık [-2,118, -2,101]'e sıkışıyor, encoder'a neredeyse sabit bir düzlem gidiyordu. BatchNorm eğitim kipinde batch istatistikleriyle bu sinyali geri büyüttüğünden train loss düşüyor, değerlendirme kipinde running istatistikleriyle batch istatistikleri arasındaki fark aynı oranda büyütüldüğünden doğrulama çıktısı her epoch farklı dağılıma kayıyordu.

(b) AMP altında Dice teriminin taşması. Yumuşak Dice paydasındaki olasılık toplamı 262.144 piksel üzerinden alındığından, ortalama tahmin olasılığı $\sim 0,25$ 'i geçtiğinde 16-bit üst sınırını (65.504) aşıp sonsuza dönüyordu. Dice 0, Dice Loss sabit 1 oluyor ve gradyan üretmiyordu. Eğitimin başında ve yüksek yoğunluklu vakalarda tetikleniyordu. Loss hesabı 32-bit'e alınarak düzeltildi.

Düzeltilmelerin ardından ilk epoch doğrulama Dice'ı 0,1071'den 0,2749'a çıktı. Raporlanan tüm sonuçlar düzeltme sonrası deneylere aittir.


3. Model Sonuçları

Tüm metrikler doğrulama setinin tamamı (89 vaka) üzerinde, en iyi doğrulama Dice'ını veren kontrol noktasıyla hesaplanmıştır. std ve SEM görüntü başına Dice dağılımından türetilmiştir.


3.1 U-Net + ResNet34

Val Loss	Dice	IoU	Precision	Recall	F1	std	SEM	Parametre	En iyi epoch
0,2624	0,8059	0,6922	0,8153	0,8392	0,8059	0,1352	0,0143	24.436.369	54

Dice, IoU ve val loss bakımından birinci. Eğitim 70 epoch'un tamamını kullandı. ReduceLROnPlateau yedi kez tetiklendi ($2,5 \times 10^{-4} \rightarrow 2,0 \times 10^{-6}$). Dice'ın epoch 29-32 ve 36-37'deki sıçramaları ilk iki LR düşüşünü takip ediyor, epoch 25'teki 0,7877 platosu LR düşüşüyle aşıldı. Son 10 epoch'ta val loss 0,2633-0,2644 bandında. Train/val loss makası epoch 19-20'de açıldı, epoch 45'ten sonra +0,049'da sabitlendi.



Şekil 1. U-Net + ResNet34 eğitim eğrileri, 70 epoch. Sağ alt panel LR takvimi; F1 ikili segmentasyonda Dice ile özdeş olduğundan ayrı panel verilmemiştir.




Şekil 2. U-Net + ResNet34 — beş sabit doğrulama vakası. Orijinal | uzman maskesi | model tahmini. Vakalar tüm modellerde sabit seed ile aynı.


3.2 U-Net++ + ResNet34

Val Loss	Dice	IoU	Precision	Recall	F1	std	SEM	Parametre	En iyi epoch
0,2717	0,7980	0,6818	0,8162	0,8310	0,7980	0,1373	0,0146	26.078.609	50

Encoder 3.1 ile aynı, tek değişken decoder. Aradaki 0,0079'luk fark doğrudan U-Net → U-Net++ geçişine atfedilebilir ve eşleşmiş validation karşılaştırmasında %5 eşliğini geçmiyor ($p = 0,054$). Tablodaki en yüksek precision (0,8162) ve en düşük R-P makası (+0,0148). Nested skip connection'lar nedeniyle batch 16→12 düşürüldü.



Şekil 3. U-Net++ + ResNet34 eğitim eğrileri, 66 epoch. Sağ alt panel LR takvimi; F1 ikili segmentasyonda Dice ile özdeş olduğundan ayrı panel verilmemiştir.




Şekil 4. U-Net++ + ResNet34 — beş sabit doğrulama vakası. Orijinal | uzman maskesi | model tahmini. Vakalar tüm modellerde sabit seed ile aynı.


3.3 SegFormer-B2

Val Loss	Dice	IoU	Precision	Recall	F1	std	SEM	Parametre	En iyi epoch
0,2756	0,7932	0,6742	0,7883	0,8396	0,7932	0,1340	0,0142	27.347.393	33

Tek transformer tabanlı model. nvidia/segformer-b2-finetuned-ade-512-512 ağırlıklarından fine tuning, tek LR (1×10^{-4}), encoder/decoder ayrımı yok. Dice bakımından üçüncü, ancak R-P makası +0,0513 ile U-Net ailesinin iki katından fazla.



Şekil 5. SegFormer-B2 eğitim eğrileri, 49 epoch. Sağ alt panel LR takvimi; F1 ikili segmentasyonda Dice ile özdeş olduğundan ayrı panel verilmemiştir.




Şekil 6. SegFormer-B2 — beş sabit doğrulama vakası. Orijinal | uzman maskesi | model tahmini. Vakalar tüm modellerde sabit seed ile aynı.


3.4 DeepLabV3+ + ResNet50

Val Loss	Dice	IoU	Precision	Recall	F1	std	SEM	Parametre	En iyi epoch
0,2906	0,7811	0,6591	0,7773	0,8293	0,7811	0,1409	0,0149	26.677.585	39

Loss precision tarafında, recall 0,8293 ile 3.1'e yakın, precision 0,7773 ile belirgin geride. R-P +0,0520. Zirve epoch 39, duruş epoch 54 — epoch sayısını değiştirmek bu deneyde sonucu değiştirmedir.



Şekil 7. DeepLabV3+ + ResNet50 eğitim eğrileri, 55 epoch. Sağ alt panel LR takvimi; F1 ikili segmentasyonda Dice ile özdeş olduğundan ayrı panel verilmemiştir.




Şekil 8. DeepLabV3+ + ResNet50 — beş sabit doğrulama vakası. Orijinal | uzman maskesi | model tahmini. Vakalar tüm modellerde sabit seed ile aynı.


3.5 DeepLabV3+ + EfficientNet-B3

Val Loss	Dice	IoU	Precision	Recall	F1	std	SEM	Parametre	En iyi epoch
0,3008	0,7751	0,6497	0,7517	0,8420	0,7751	0,1349	0,0143	11.680.185	31

Tablonun en yüksek recall'u (0,8420) ve en düşük precision'ı (0,7517). R-P +0,0903 ile altı modelin en yüksek. Epoch 2'de Dice 0,18 / recall 0,12'ye düşüp epoch 7'de toparladı (warmup), kalıcı etkisi olmadı.



Şekil 9. DeepLabV3+ + EfficientNet-B3 eğitim eğrileri, 47 epoch. Sağ alt panel LR takvimi; F1 ikili segmentasyonda Dice ile özdeş olduğundan ayrı panel verilmemiştir.




Şekil 10. DeepLabV3+ + EfficientNet-B3 — beş sabit doğrulama vakası. Orijinal | uzman maskesi | model tahmini. Vakalar tüm modellerde sabit seed ile aynı.

3.6 U-Net + EfficientNet-B0


Val Loss	Dice	IoU	Precision	Recall	F1	std	SEM	Parametre	En iyi epoch
0,4158	0,7419	0,6120	0,7665	0,7915	0,7419	0,1641	0,0174	6.251.469	15

Eşleşmiş validation karşılaştırmasında en iyi modelden anlamlı biçimde geride kalan en büyük fark (0,0642; $p = 4,5 \times 10^{-13}$). Zirve epoch 15, duruş epoch 30 — epochların yarısını kullanmadan early stopping ile kesildi. Encoder dört kat küçük olmasına rağmen ortalama train/val makası +0,081; aynı epoch aralığında 3.1'de +0,021.

Bu deney bir protokol etkisini görünür kılıyor: erken durdurma val Dice'ı, LR scheduler'ı val loss'u izliyor. Bu modelde ikisi ayrıştı — Dice epoch 15'te platoya girdi, val loss epoch 25'e kadar iyileşti. Protokol altı modelde aynı uygulandığından karşılaştırma etkilenmiyor, ancak gürültülü Dice eğrisine sahip modeller sistematik olarak daha erken kesiliyor.



Şekil 11. U-Net + EfficientNet-B0 eğitim eğrileri, 31 epoch. Sağ alt panel LR takvimi; F1 ikili segmentasyonda Dice ile özdeş olduğundan ayrı panel verilmemiştir.



Şekil 12. U-Net + EfficientNet-B0 — beş sabit doğrulama vakası. Orijinal | uzman maskesi | model tahmini. Vakalar tüm modellerde sabit seed ile aynı.

4. Karşılaştırma

4.1 Genel tablo

#	Model	Val Loss	Dice	IoU	Precision	Recall	F1	R-P	Parametre	En iyi epoch
1	U-Net + ResNet34	0,2624	0,8059	0,6922	0,8153	0,8392	0,8059	+0,0239	24.436.369	54
2	U-Net++ + ResNet34	0,2717	0,7980	0,6818	0,8162	0,8310	0,7980	+0,0148	26.078.609	50
3	SegFormer-B2	0,2756	0,7932	0,6742	0,7883	0,8396	0,7932	+0,0513	27.347.393	33
4	DeepLabV3+ + ResNet50	0,2906	0,7811	0,6591	0,7773	0,8293	0,7811	+0,0520	26.677.585	39
5	DeepLabV3+ + EfficientNet-B3	0,3008	0,7751	0,6497	0,7517	0,8420	0,7751	+0,0903	11.680.185	31
6	U-Net + EfficientNet-B0	0,4158	0,7419	0,6120	0,7665	0,7915	0,7419	+0,0250	6.251.469	15

R-P: recall – precision farkı (bkz. 4.2). İkili segmentasyonda F1 = Dice.

4.2 Decoder tipi ve aşırı segmentasyon

Modeller arasındaki en düzenli örüntü toplam Dice'ta değil, recall ile precision arasındaki farkta görülmektedir. Decoder'ın ayrıntıyı nasıl geri getirdiğine göre iki grup oluşmakta ve gruplar arasında örtüşme bulunmamaktadır:

ince skip connection (U-Net, U-Net++)	: +0,0148	+0,0239	+0,0250	max 0,0250
kaba 4x büyütme (DeepLabV3+, SegFormer)	: +0,0513	+0,0520	+0,0903	min 0,0513
				boşluk 0,0263

Ayrım encoder'dan bağımsızdır. SegFormer'ın MiT-B2 encoder'ı diğerlerinin konvolüsyonel encoder'larıyla akraba olmadığı halde kaba büyütme grubuyla aynı davranışı göstermektedir. EfficientNet encoder'ı ise hem U-Net (+0,0250) hem DeepLabV3+ (+0,0903) modellerinde yer almasına rağmen fark decoder'a göre değişmektedir.

Her ölçekte skip connection taşıyan decoder'lar konumsal ayrıntıyı koruyup sınırları takip etmektedir. Sonndan tek adımda 4x büyütenler dens dokuyu bulmakta (grubun recall değerleri yüksek) ancak sınırlardan taşarak yanlış pozitif üretmektedir. Hedef bölgenin sınırları dağınık ve süreksiz olduğundan bu hata belirginleşmektedir. İlişki gözlemseldir ve kontrollü değildir — DeepLabV3+ modellerinin encoder'ları da farklıdır; iddia "decoder tipi tek başına bu farkı yaratır" değil, "recall–precision farkı encoder'a değil decoder tipine göre gruplanmaktadır" biçimindedir.

4.3 Farkların istatistiksel değerlendirmesi

Görüntü başına Dice standart sapması 0,134-0,164 aralığındadır. Bu sapmanın büyük kısmı modeller arası farkı değil vakalar arası zorluk farkını yansıttığından, eşleşmemiş karşılaştırma bu tasarımda gücü

düşürmektedir. Altı model aynı 89 vakada aynı sırayla değerlendirildiğinden vaka başına fark alınarak ortak varyans sadeleştirilebilir. Aşağıda iki yaklaşım karşılaştırılmakta olup referans U-Net + ResNet34'tür.

Wilcoxon işaretli sıra testi, modellerin aynı doğrulama vakaları üzerindeki performans farkını değerlendirmek amacıyla uygulanmıştır. Ancak her modelin tek seed ile eğitilmiş olması nedeniyle eğitim kaynaklı varyans istatistiksel analize dahil edilmemiştir.

Model	Fark	Eşleşmemiş SEM	Eşleşmiş SEM	SEM oranı	t	Wilcoxon p	Sonuç
U-Net++ + ResNet34	0,0078	0,0204	0,0032	6,4×	2,40	0,054	ayirt edilemez
SegFormer-B2	0,0127	0,0201	0,0042	4,8×	3,05	$4,7 \times 10^{-4}$	anlamli
DeepLabV3+ + ResNet50	0,0247	0,0206	0,0038	5,4×	6,43	$2,2 \times 10^{-8}$	anlamli
DeepLabV3+ + EfficientNet-B3	0,0309	0,0202	0,0046	4,4×	6,67	$1,1 \times 10^{-8}$	anlamli
U-Net + EfficientNet-B0	0,0642	0,0225	0,0091	2,5×	7,05	$4,5 \times 10^{-13}$	anlamli

Eşleşmiş standart hatalar 2,5-6,4 kat küçüktür. Eşleşmemiş karşılaştırmaya göre yalnızca bir model anlamli biçimde geride kalırken, eşleşmiş validation karşılaştırmasına göre beş modelin dördü U-Net + ResNet34'ten anlamli biçimde geridedir; yalnızca U-Net++ sınırda kalmaktadır ($p = 0,054$).

Test, sıralamanın vaka örnekleme gürültüsünden kaynaklanmadığını göstermektedir. Kapsamadığı iki nokta: (a) her mimari tek seed ile bir kez eğitildiğinden eğitim rastgeleliği hesaba katılmamıştır; (b) farkların büyüklüğü 0,008-0,031 aralığındadır ve literatürde radyologlar arası uyum Dice = $0,76 \pm 0,17$ olarak bildirilmektedir (Larroza vd., 2022) — sıralama gerçek, pratik karşılığı sınırlıdır.

4.4 Encoder ve decoder seçimlerinin birlikte etkisi

İlk üç model tamamlandığında iki faktörlü bir tasarım oluşmuştu. Decoder sabitken encoder değişimi 0,0640, encoder sabitken decoder değişimi 0,0079 fark üretiyordu. Buradan encoder'ın belirleyici olduğu sonucuna varılmıştı. Dördüncü model eklendiğinde bu genelleme geçerliliğini yitirmektedir. Encoder ve decoder etkileri bağımsız değil, birbirine bağlıdır:

	ResNet	EffNet	encoder etkisi
U-Net	0,8059	0,7419	-0,0640
DeepLabV3+	0,7811	0,7751	-0,0060
decoder etkisi	-0,0248	+0,0332	

ResNet → EfficientNet geçişinin bedeli U-Net decoder'ıyla 0,0640, DeepLabV3+ decoder'ıyla 0,0060'tır; decoder etkisinin işareti encoder'a göre değişmektedir. EfficientNet-B3 (11,7M), EfficientNet-B0'ın (6,3M) iki katına yakındır ve fark decoder'dan değil encoder boyutundan kaynaklanıyor olabilir. İki açıklamayı ayıracak eksik model U-Net + EfficientNet-B3'tür ve bu çalışmada eğitilmemiştir.

4.5 Model boyutu ve checkpoint'ler

Kontrol noktaları model ağırlıklarının yanı sıra optimizier, scheduler, scaler durumlarını, epoch sayacını ve RNG durumlarını içermekte, Drive üzerinde saklanmaktadır.

Model	Parametre	best.pt epoch	Kaydedilen val Dice	Toplam epoch
U-Net + ResNet34	24.436.369	54	0,80585975	70
U-Net++ + ResNet34	26.078.609	50	0,79801751	66
SegFormer-B2	27.347.393	33	0,79320747	49
DeepLabV3+ + ResNet50	26.677.585	39	0,78111506	55
DeepLabV3+ + EfficientNet-B3	11.680.185	31	0,77506189	47
U-Net + EfficientNet-B0	6.251.469	15	0,74193355	31

Parametre sayısı sıralamayı açıklamamaktadır. İlk dört model 24,4M-27,3M bandında toplanmakta, Dice değerleri 0,7811-0,8059 arasında dağılmaktadır. En çok parametrelili model üçüncü, en az parametrelili modeli birincidir. DeepLabV3+ + EfficientNet-B3, ResNet50 muadilinin parametresinin %44'üyle 0,0060 geride kalmaktadır. 447 eğitim görüntüsüyle ek kapasite karşılık bulmamaktadır.

5. En Başarılı Model

U-Net + ResNet34 — Dice 0,8059 · IoU 0,6922 · Precision 0,8153 · Recall 0,8392 · F1 0,8059 · Val Loss 0,2624 · 24.436.369 parametre · en iyi epoch 54

Dice, IoU ve val loss bakımından birinci; eşleşmiş validation karşılaştırmasında beş alternatifin dördünden anlamlı biçimde üstün (p aralığı $4,7 \times 10^{-4} - 4,5 \times 10^{-13}$), U-Net++ ile sınırda ($p = 0,054$).

Decoder mimarisi. Her ölçekte skip connection taşıdığından sınır ayrıntısını korumaktadır; R-P farkı +0,0239 ile ince skip grubunun içindedir. Hedef dokunun dağınık ve süreksiz sınırlara sahip olduğu bu görevde belirleyici özellik budur.

Encoder transferi. Decoder sabitken ResNet34 → EfficientNet-B0 geçişi 0,0640 kaybettirmektedir. Ölçülebilir yansıması overfitting davranışdır: EfficientNet-B0 modeli dört kat küçük olmasına rağmen ortalama train/val makası +0,081, seçilen modelde +0,028'dir.

Kapasite-veri dengesi. İlk dördün en küçüğü olmasına rağmen birincidir; 447 eğitim görüntüsü ölçeğinde ek kapasitenin karşılık bulmadığı 4.5'te görülmektedir.

Eğitim kararlılığı. 70 epoch bütçesini tam kullanan tek modeldir. 7 LR düşüşünün her birine karşılık vermiş, epoch 25'teki platoyu aşarak epoch 54'te 0,8059'a ulaşmıştır. Son 10 epoch'ta val loss bandı 0,0011 genişliğindedir.

Hata profili. Precision (0,8153) ve recall (0,8392) birbirine yakındır. Görevin klinik karşılığı alan tabanlı yoğunluk yüzdesi tahmini olduğundan dengeli profil, sistematik olarak taşan (DeepLabV3+ + EfficientNet-B3, +0,0903) veya eksik segmente eden bir modele göre avantajlıdır.

Seçim, U-Net++ ile arasındaki farkın sınırda olması ve tek eğitim koşusu kısıtı dikkate alınarak "tüm toplam metriklerde önde ve U-Net++ dışındaki alternatiflere karşı daha yüksek toplam segmentasyon performansı sağlayan model" olarak okunmalıdır.

6. Sonuç

Altı model aynı veri işleme, augmentation, loss ve genel eğitim protokolü altında değerlendirilmiştir. Mimari gereksinimlere göre batch size ve learning rate gibi model-spesifik hiperparametreler ayarlanmıştır. En yüksek Dice'ı U-Net + ResNet34 verdi (0,8059); U-Net++ + ResNet34 ikinci sırada yer aldı (0,7980) ve aradaki fark eşleşmiş validation karşılaştırmasında %5 eşliğini geçmedi. En geride U-Net + EfficientNet-B0 kaldı (0,7419).

Çalışmanın en düzenli bulgusu decoder mimarisi ile aşırı segmentasyon eğilimi arasındaki ilişkidir. İnce ölçekli skip connection taşıyan decoder'ların R-P farkı 0,025'in altında, sondan tek adımda büyüyenlerin 0,051'in üzerinde kalmış, altı model ve dört farklı decoder mimarisi boyunca gruplar arasında örtüşme gözlenmemiştir. Bu, tek bir toplam skorda görünmeyen ancak model seçiminde karşılığı olan bir davranış farkıdır. Yüksek recall'un öncelikli olduğu senaryolarda DeepLabV3+ ailesinin profili, sınır doğruluğunun önemli olduğu alan ölçümü senaryolarında U-Net ailesi tercih edilebilir.

Parametre sayısı sıralamayı açıklamamaktadır; ilk dört model dar bir parametre bandında toplanmasına rağmen band içindeki ilişki ters yöndedir. Ayrıca ilk üç modelden çıkarılan "encoder decoder'dan daha belirleyicidir" genellemesi dördüncü model eklendiğinde geçerliliğini yitirmiş; encoder ve decoder etkilerinin bağımsız olmadığı görülmüştür (bkz. 4.4).

6.1 Sınırlamalar

- Her mimari tek seed ile (seed 42) bir kez eğitilmiştir. Eşleşmiş validation vakaları tekrar birimi olarak almakta, eğitim koşusu varyansını kapsamamaktadır. Çalışmanın en önemli istatistiksel sınırlamasıdır.
- Ayrı bir test seti yoktur, tüm sonuçlar doğrulama seti üzerindedir ve checkpoint seçimi de aynı set üzerinde yapıldığından bir miktar iyimserlik beklenmelidir. Çapraz doğrulama uygulanmamıştır.
- Referans etiketin kendisi belirsizdir (radyologlar arası uyum Dice = $0,76 \pm 0,17$); modeller arası 0,008-0,031'lik farklar bu belirsizliğin bir merteye altındadır.
- Mimari başına hiperparametre araması yapılmamıştır. Özellikle EfficientNet encoder'larının farklı bir öğrenme oranı rejimine ihtiyaç duyup duymadığı sınırlanmıştır.
- 512×512 karelerin yaklaşık %55'i boş dolgudur. Meme bounding box çevresine kırpma etkin çözünürlüğü artırabilirdi; aynı görüntü alanında yürütülen kitle tespiti çalışmasında kırpma ablasyonu kayda değer kazanç sağlamadığı için (mAP@50: 0,6928 kırpmasız / 0,6901 kırpılmış) ve karşılaştırılabilirliği korumak adına uygulanmamıştır.
- Erken durdurma val Dice'ı, LR scheduler'ı val loss'u izlemektedir. İki ölçüt U-Net + EfficientNet-B0 modelinde ayrılmıştır; protokol tüm modellerde aynı olduğundan karşılaştırma etkilenmemekle birlikte gürültülü Dice eğrisine sahip modeller daha erken kesilmektedir.
- Kullanılan veri sürümünde meme alanı maskesi bulunmadığından, tahmin maskesinden alan tabanlı yoğunluk yüzdesi hesaplanamamış ve klinik olarak Dice'tan daha yorumlanabilir olan bu ölçüt raporlanamamıştır.

Kaynaklar

1. Behravan, H., Gudhe, N. R., Okuma, H., Sudah, M., & Mannermaa, A. (2024). A dataset of mammography images with area-based breast density values, breast area, and dense tissue segmentation masks. *Data in Brief*. [S2352340924009429](https://doi.org/10.1016/j.dib.2024.109429) — data.mendeley.com/datasets/tdx3h2fn9v
2. Larroza, A. vd. (2022). Breast Dense Tissue Segmentation with Noisy Labels: A Hybrid Threshold-Based and Mask-Based Approach. *Diagnostics*. [PMC9406546](https://doi.org/10.3390/diagnostics12050546)

3. Saffari, N. vd. (2020). Fully Automated Breast Density Segmentation and Classification Using Deep Learning. *Diagnostics*, 10(11), 988. [PMC7700286](#)
4. He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. *CVPR*. — ResNet34 ve ResNet50 encoder'ları
5. Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. *ICML*. — EfficientNet-B0 ve EfficientNet-B3 encoder'ları
6. Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. *MICCAI*.
7. Zhou, Z. vd. (2018). UNet++: A Nested U-Net Architecture for Medical Image Segmentation. *DLMIA*.
8. Chen, L.-C. vd. (2018). Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation. *ECCV*.
9. Xie, E. vd. (2021). SegFormer: Simple and Efficient Design for Semantic Segmentation with Transformers. *NeurIPS*.
10. Nguyen, H. T. vd. (2023). VinDr-Mammo: A large-scale benchmark dataset for computer-aided diagnosis in full-field digital mammography. *Scientific Data*.