

Hiperparametre Optimizasyonu — Deney Raporu

U-Net + ResNet34 · Meme yoğunluğu segmentasyonu

1. Amaç ve Kapsam

Ana çalışmada altı model karşılaştırılmış, en yüksek Dice'ı U-Net + ResNet34 vermiştir (0,8059). Söz konusu çalışmada hiperparametreler literatür taramasıyla belirlenmiş, mimari başına ayrı bir arama yürütülmemiştir. Bu eksiği kapatmak üzere aynı model üzerinde yedi deney yapılmıştır. Eğitim gerektirmeyen bir karar eşiği taraması ve altı yeniden eğitim.

Amaç, literatürden alınan ayarların bu veri seti için uygun olup olmadığını ve hedefli değişikliklerle daha yüksek Dice elde edilip edilemeyeceğini sınamaktır.

2. Yöntem

2.1 Deney tasarımı

Her deney baseline'dan yalnızca tek bir ayarı değiştirmiştir. Kademeli arama, yani bir aşamanın kazananını sabitleyip sonrakine geçme yaklaşımı kullanılmamıştır. Böylece her sonuç tek başına yorumlanabilmekte ve seçim yanlılığı aşamalar boyunca birikmemektedir.

Veri bölünmesi (447 eğitim / 89 doğrulama), ön işleme, seed (42), değerlendirme kodu ve en iyi checkpoint seçim ölçütü ana çalışmayla aynı tutulmuştur. Baseline bu deney setinde yeniden ölçülmüş ve ana çalışmayla aynı sonucu vermiştir (Dice 0,805860 · IoU 0,692159 · Precision 0,815256 · Recall 0,839154 · en iyi epoch 54); bu, iki notebook arasındaki tutarlılığı doğrulamaktadır.

2.2 Model seçimi

Ana çalışmada ilk iki sırayı U-Net + ResNet34 (0,8059) ve U-Net++ + ResNet34 (0,7980) almış, aralarındaki fark eşleşmiş validation karşılaştırmasında %5 eşiğini geçmemiştir (p = 0,054). Her ikisi de aynı encoder'ı kullanmaktadır. Buna karşın arama yalnızca birinci model üzerinde yürütülmüştür. İki modelde paralel arama yürütmek yerine birinde arayıp kazanan ayarı diğerinde tekrarlamak, elde edilen kazancın gerçek mi yoksa doğrulama gürültüsü mü olduğunu ayırt etmeyi sağlamaktadır. İki model aynı encoder'ı paylaştığından, özellikle öğrenme oranı bulgularının transfer olması beklenir. Transfer gerçekleşmezse kazancın veriye özgü olduğu anlaşılır. Paralel arama bu ayrımı yapma imkânını ortadan kaldırırdı.

2.3 İstatistiksel karşılaştırma

Karşılaştırmalar aynı 89 doğrulama vakasında, vaka başına fark üzerinden (eşleşmiş validation karşılaştırması) yapılmıştır. Ölçülen görüntü başına Dice standart sapması ~0,14'tür ve bunun büyük kısmı modeller arası farkı değil vakalar arası zorluk farkını yansıtmaktadır; eşleşmiş karşılaştırma bu ortak bileşeni sadeleştirerek küçük gerçek farkların görülmesini sağlamaktadır. p değerleri Wilcoxon işaretli sıra testinden gelmektedir.


Altı karşılaştırma birden yürütüldüğünden çoklu karşılaştırma düzeltilmesi uygulanmış, anlamlılık eşiği Bonferroni ile 0,05 / 6 = 0,0083 alınmıştır. Her deney tek seed ile eğitildiğinden eğitim kaynaklı varyans analize dâhil edilmemiştir.

3. Karar Eşiği Taraması

Ana çalışmanın tamamında karar eşiği 0,50'de sabittir. Optimal eşik eğitim seti üzerinde aranmıştır. Validation setinde aramak, sonucun yine aynı sette raporlanması nedeniyle yapay kazanç üretti. Eğitim seti beş kat büyüktür ve bu tür bir sızıntı oluşturmamaktadır. Bu deney yeniden eğitim gerektirmemekte, mevcut best.pt ile yalnızca çıkarım yapılmaktadır.

Eşik	0,30	0,35	0,40	0,45	0,50	0,55	0,60	0,65	0,70
Eğitim Dice	0,8558	0,8573	0,8584	0,8591	0,8595	0,8596	0,8595	0,8588	0,8576
Doğrulama Dice	0,8061	0,8064	0,8064	0,8063	0,8059	0,8051	0,8042	0,8029	0,8010

Koyu değerler satır maksimumudur. Seçim eğitim satırına göre yapılmıştır.



Şekil 1. Karar eşiği taraması. Eğitim eğrisi 0,45-0,60 aralığında düzdür; eğitim ve doğrulama optimumları farklı eşiklerde oluşmaktadır.

Kazanç elde edilmemiş, eşik 0,50'de bırakılmıştır. Üç gözlem öne çıkmaktadır.

- **Eğri düzdür.** 0,45-0,60 arasındaki dört noktada eğitim Dice yayılımı yalnızca 0,0005'tir. Bu bir optimum değil sayısal gürültüdür; `argmax` 'ın 0,55'i seçmesi anlamlı bir tercih sayılamaz. Düz bir eğride varsayılan değer ancak belirli bir marjı aşan iyileşme için değiştirilmelidir, burada öyle bir marj bulunmamaktadır.
- **Eğitim ve doğrulama optimumları ayrışmaktadır** (0,55 / 0,35). Model eğitim görüntülerinde daha güvenli tahmin ürettiğinden orada daha yüksek eşik uygun düşmektedir. Eğitimde seçip doğrulamada uygulama yaklaşımı yöntemsel olarak temiz olmakla birlikte bu parametrede transfer sağlamamıştır.
- **Doğrulamanın kendi optimumu da kazanç vermemektedir.** Eşik 0,35-0,40 ile doğrulama Dice 0,8064'tür; baseline'a göre +0,0005 (0,03 SEM). Doğrulamada arama yapıp yanlışlık göze alınsaydı bile sonuç değişmezdi.

Yan bulgu: eşik 0,50'de eğitim Dice 0,8595, doğrulama 0,8059'dur; aradaki fark +0,0536. Ana çalışmada bildirilen train/val loss makasıyla (+0,049) tutarlıdır ve hafif overfitting'i bağımsız bir ölçütle doğrulamaktadır.

4. Denenen Ayarlar

Deney	Değişen ayar	Baseline	Denenen	Gerekçe
no_vflip	Dikey çevirme olasılığı	0,3	0,0	Mamografide dens doku dağılımı anatomik olarak yapıldır; dikey çevirmenin bu ön bilgiyi bozduğu ve literatürde sık tercih edilmediği değerlendirilmiştir.
enc_lr_3e5	Encoder LR	5×10^{-5}	3×10^{-5}	ImageNet ön-eğitimli encoder'ın küçük veri setinde fazla güncellenmesinin overfitting ürettiği hipotezi. Ana çalışmada train/val maksasının +0,049'da sabitlenmesi bu yönde işaret sayılmıştır. Literatürde encoder için 1×10^{-5} - 3×10^{-5} bandı yaygındır.
enc_lr_1e5	Encoder LR	5×10^{-5}	1×10^{-5}	
cosine	Scheduler	ReduceLROnPlateau	CosineAnnealingLR	Ön-eğitimli encoder'ın daha yumuşak güncellenmesi ve son epoch'larda daha iyi yerel minimum bulunması beklentisi; son yıllarda segmentasyon çalışmalarında kullanımı artmıştır.
dice_focal	Loss	Dice + BCE	Dice + Focal ($\alpha=0,25$, $\gamma=2$)	Kolay piksellerin ağırlığı azaltılarak zor sınır bölgelerine odaklanma.
dice_tversky	Loss	Dice + BCE	Dice + Tversky ($\alpha=0,7$, $\beta=0,3$)	Baseline'da recall (0,8392) precision'dan (0,8153) yüksektir; yanlış pozitifin daha ağır cezalandırılarak dengenin precision lehine kaydırılması.


Değiştirilmeyen ayarlar: batch 16, decoder LR $2,5 \times 10^{-4}$, AdamW, weight decay 1×10^{-4} , 3 epoch doğrusal warmup, gradyan kırpm (max_norm 1,0), AMP, görüntü boyutu 512×512, maksimum 70 epoch, patience 15.

cosine deneyinde erken durdurma devre dışı bırakılmıştır (patience = 70). Kosinüs çevrimi kesildiğinde model düşük öğrenme oranındaki ince ayar fazına girememekte ve yöntem haksız biçimde dezavantajlı duruma düşmektedir. Bu, bir deneyde bilinçli olarak değiştirilen tek ek ayardır.

5. Sonuçlar

Deney	Dice	Fark	Eşleşmiş SEM	Wilcoxon p	Karar	IoU	Precision	Recall	R-P	En iyi epoch	Toplam epoch
BASELINE	0,8059	—	—	—	referans	0,6922	0,8153	0,8392	+0,0239	54	70
dice_focal	0,8015	-0,0043	0,0026	0,0074	anlamli düşüş	0,6859	0,7979	0,8482	+0,0503	46	62
no_vflip	0,7992	-0,0067	0,0033	0,0221	ayirt edilemez	0,6822	0,8083	0,8397	+0,0313	59	70
enc_lr_3e5	0,7978	-0,0081	0,0038	0,0094	ayirt edilemez	0,6804	0,8077	0,8345	+0,0268	48	64
cosine	0,7956	-0,0102	0,0030	0,0017	anlamli düşüş	0,6794	0,8206	0,8199	-0,0007	50	70
dice_tversky	0,7953	-0,0106	0,0031	0,0004	anlamli düşüş	0,6789	0,7917	0,8465	+0,0548	28	44
enc_lr_1e5	0,7847	-0,0211	0,0068	0,0004	anlamli düşüş	0,6671	0,8092	0,8145	+0,0053	63	70

Anlamlılık eşiği Bonferroni düzeltmesiyle 0,0083. R-P: recall - precision farkı. Süreler NVIDIA T4 üzerinde ölçülmüştür; no_vflip sıradaki ilk deney olduğundan veri önbelleği soğuktur ve epoch başına süresi diğerlerinden yüksektir.



Şekil 2. Altı deneyin doğrulama Dice değerleri. Kesikli çizgi baseline, hata çubukları standart hatadır. Kırmızı: Bonferroni düzeltmesinden sonra anlamlı düşüş. Gri: baseline ile ayırt edilemez.

6. Değerlendirme

Denenen hiçbir değişiklik baseline'ı geçmemiştir. Altı deneyin dördü Bonferroni düzeltmesinden sonra anlamlı düşüş göstermiş, ikisi baseline'dan ayırt edilememiştir. Literatür taramasıyla belirlenen ayarlar bu veri seti için yerel bir optimumda görünmektedir.

6.1 Öğrenme oranı

Encoder öğrenme oranı düşürüldükçe Dice monoton biçimde azalmaktadır:

encoder LR	5x10 ⁻⁵ (baseline)	->	Dice 0,8059	
	3x10 ⁻⁵	->	Dice 0,7978	(-0,0081)
	1x10 ⁻⁵	->	Dice 0,7847	(-0,0211)

Bu sonuç, encoder'ın fazla güncellendiği ve overfitting ürettiği hipotezini çürütmektedir. ImageNet öznetelikleri mamografi dokusuna uyum sağlamak için belirgin bir güncelleme gerektirmektedir; doğal görüntülerle mamografi arasındaki alan farkı, düşük öğrenme oranının yeterli olamayacağı kadar büyüktür. Nitekim `enc_lr_1e5` doğrulama Dice'ını epoch 63'e kadar iyileştirmeye devam etmiş, yani overfitting değil yetersiz öğrenme göstermiştir.

Eğilim tek yönlü olduğundan doğal devam adımı, encoder öğrenme oranının 5×10^{-5} 'in üzerine çıkarılmasını sınamaktır (örneğin 7×10^{-5} ve 1×10^{-4}). Bu çalışmada yapılmamıştır.

6.2 Dikey çevirme

Anatomik tutarlılık gerekçesiyle kapatıldığında Dice 0,0067 düşmüştür. Fark Bonferroni sonrası anlamlı değildir ($p = 0,0221$), ancak yön beklenenin tersidir. 447 eğitim görüntülük bir sette augmentation çeşitliliğinin katkısı anatomik sadakatten daha belirleyici görünmektedir; dikey çevirme bir bozulma kaynağı değil, düzenleyici (regularizer) işlevi görmektedir.

6.3 Cosine scheduler

Bu deney tablonun en yüksek precision'ını (0,8206) ve tek negatif R-P değerini ($-0,0007$) üretmiştir; ana çalışmada U-Net ailesinde gözlenen hafif aşırı segmentasyon eğilimini ortadan kaldırmıştır. Buna karşılık toplam Dice 0,0102 düşmüştür. Sınır doğruluğunun toplam örtüşmeden öncelikli olduğu bir kullanımda bu ayar tercih edilebilir.

Açıklanamayan sonuç. Tversky kaybında $\alpha=0,7$ seçilerek yanlış pozitifin daha ağır cezalandırılması ve precision'ın yükselmesi hedeflenmişti. Gerçekleşen bunun tersidir: precision 0,8153'ten 0,7917'ye düşmüş, recall 0,8392'den 0,8465'e yükselmiştir. Loss fonksiyonunun TP/FP/FN tanımları doğrulanmıştır. Olası açıklama, bu deneyin en erken sonlanan koşu olmasıdır (en iyi epoch 28, erken durdurma epoch 43); asimetrik loss doğrulama kaybı eğrisini değiştirerek durdurma ölçütünü erken tetiklemiş olabilir. Sonuç, loss fonksiyonunun kalitesinden çok erken sonlanmayla karışmış durumdadır ve bu çalışmada ayrıştırılamamıştır.

7. Sınırlamalar

Ayrı bir test seti bulunmadığından, doğrulama setinde yürütülen her hiperparametre araması raporlanan sonucu iyimser yönde şişirme riski taşımaktadır. Altı konfigürasyon denenip en iyisi seçildiğinde beklenen yapay kazanç, ölçülen SEM (0,0143) üzerinden yaklaşık +0,018 Dice'tir; bu değer ana çalışmadaki ilk üç modelin toplam farkından (0,0127) büyüktür. Arama bu nedenle dar tutulmuş, konfigürasyonlar önceden belirlenmiş ve tümü raporlanmıştır; yalnızca en iyisinin bildirilmesi bu yanlışlığı gizlerdi. Söz konusu risk somut olarak gerçekleşmemiştir: hiçbir deney baseline'ı geçmediğinden seçilecek bir kazanan oluşmamış, dolayısıyla seçim yanlışlığı da doğmamıştır.

- Her deney tek seed (42) ile bir kez eğitilmiştir; eşleşmiş karşılaştırma vakaları tekrar birimi olarak almakta, eğitim koşusu varyansını kapsamamaktadır. Gözlenen 0,004-0,021 aralığındaki farkların ne kadarının eğitim rastgeleliğinden geldiği ölçülememiştir.
- Tek faktör değiştirme tasarımı ayarlar arasındaki etkileşimleri görememektedir. Örneğin daha düşük encoder öğrenme oranı, daha uzun epoch bütçesiyle birlikte farklı sonuç verebilirdi.
- Sonuçlar yalnızca U-Net + ResNet34 için geçerlidir. Bir ayarın gerçekten etkili olduğunun doğrulanması için kazanan konfigürasyonun ikinci bir model üzerinde (U-Net++ + ResNet34) tekrarlanması gerekir (bkz. 2.2); kazanan çıkmadığından bu adım uygulanmamıştır.
- Eşik taramasında yalnızca tek bir global eşik denenmiş, vaka bazında uyarlanan eşik stratejileri sınanmamıştır.

8. Sonuç

Yedi deneyin hiçbirisi U-Net + ResNet34 baseline'ını (Dice 0,8059) geçememiştir. Karar eşiği zaten optimaldir; encoder öğrenme oranının düşürülmesi, dikey çevirmenin kapatılması, cosine scheduler'a geçilmesi ve loss fonksiyonunun Focal veya Tversky ile değiştirilmesi sonucu iyileştirmemiştir. Bu bulgu, ana çalışmadaki hiperparametre seçimlerinin bu veri seti için isabetli olduğunu göstermekte ve raporun mimari başına hiperparametre araması yapılmadığına ilişkin sınırlamasını kapatmaktadır.

Elde edilen tek yönlü sinyal encoder öğrenme oranındadır: eğilim, mevcut değer altına değil üstüne çıkılması gerektiğini düşündürmektedir. Bu, sonraki deney turunun doğal başlangıç noktasıdır.