

Globally-Aware Multiple Instance Classifier Yönteminin CMMD2022 Veri Setinde Yeniden Üretilmesi

Shen ve ark. (MLMI 2019) · 18.08.2026

Çalışmanın ana bulgusu, makalenin merkezi iddiasının bu veri setinde de geçerli olmasıdır: GMIC, aynı backbone'u kullanan ResNet-22 baseline'ını 0,083 AUC farkıyla aşmaktadır ($p = 0,024$). Makalede bildirilen fark 0,073 olup, veri setinin yaklaşık 120 kat küçük olmasına rağmen aynı büyüklükte bir kazanç elde edilmiştir. Hiperparametre aramasından çıkan ilk üç konfigürasyonun ensemble'i 0,791 ile en yüksek sonucu vermekte ve tek başına tam modeli de anlamlı olarak aşmaktadır ($p = 0,029$). Buna karşılık ablasyon varyantlarının hiçbiri tam modelden istatistiksel olarak ayırt edilememektedir; Bölüm 5.4'te gösterildiği üzere bu, ablasyonların etkisiz olduğu anlamına gelmez, mevcut örneklem büyüklüğünün bu büyüklükteki farkları ölçmeye yetmediği anlamına gelir.

1. Amaç ve Kapsam

Shen ve ark., yüksek çözünürlüklü mamografi görüntülerinde tüm görüntüyü işleyen bir global ağı, saliency map'ten seçilen patch'ler üzerinde çalışan bir MIL modülü ile birleştiren GMIC mimarisini önermiştir. Bu çalışmanın amacı, söz konusu yöntemi CMMD2022 veri setinde mümkün olduğunca birebir uygulamak ve makalede bildirilen ablasyon sıralamasının bu ölçekte korunup korunmadığını ölçmektir.

Hedef, makaledeki mutlak AUC seviyesine ulaşmak değildir. Makale 229.426 tetkik üzerinde çalışırken burada 1.771 hasta bulunmaktadır; iki çalışmanın mutlak değerleri doğrudan karşılaştırılabilir nitelikte değildir. Değerlendirme, yöntemin bileşenleri arasındaki göreceli sıralama üzerinden yapılmıştır.

2. Veri


CMMD2022 veri seti (TCIA arşivi, Kaggle dağıtımı tommyngx/cmmd2022) 5.202 DICOM görüntü ve 1.775 hasta içermektedir. Eğitime hazır hale getirilirken üç eleme uygulanmıştır.

Birincisi, iki memesi de görüntülenmiş ancak yalnızca biri için biyopsi sonucu bulunan hastalarda etiketsiz kontralateral memeler (729 meme) veri dışında bırakılmıştır. Patolojik doğrulama olmadan bu memelerin negatif kabul edilmesi, etiket gürültüsü yaratacaktır.

İkincisi, arşivin uyardığı yinelenen görüntüler md5 karşılaştırmasıyla doğrulanmıştır. D1-0808 ve D1-1292 kayıtları aynı sağ CC görüntüsünü birbirine zıt sınıflarla paylaşmaktadır; benzer çakışmaların tespit edildiği toplam dört hasta veri dışı bırakılmıştır.

Üçüncüsü, bölme hasta seviyesinde yapılmış, aynı hastanın tüm görüntüleri tek bir kümede tutulmuştur. Kalan veri 1.867 meme ve 3.734 görüntüdür; eğitim, doğrulama ve test kümelerine %70/15/15 oranında ayrılmıştır.

Görüntüler 8 bit derinlikte ve ön-pencerelemiş olarak saklanmaktadır (WindowCenter 128, Width 256, VOI LUT SIGMOID). Bu ayrıntı sonuçların yorumlanmasında önem taşımaktadır: makalenin korumayı hedeflediği geniş dinamik aralık bu veri setinde baştan mevcut değildir.



Şekil 1. Sınıf, alt küme (D1/D2) ve yaş dağılımları.

Veri setinde belirgin bir confounder yapısı bulunmaktadır. Yalnızca yaş kullanıldığında 0,682; yalnızca D1/D2 alt küme göstergesi kullanıldığında 0,776; ikisi birlikte kullanıldığında 0,847 AUC elde edilmektedir. Bu nedenle birincil değerlendirme kohortu olarak D1 seçilmiştir (n = 165, 85 malign). D2 test kohortunda 115 memenin 113 tanesi malign olduğundan, bu alt kümede AUC pratik olarak tanımsızdır.

3. Yöntem

3.1 Mimari

Mimari makaledeki tanıma bağlıdır. Lokalizasyon modülü f_d olarak ResNet-22 kullanılmakta, çıktısı 1×1 konvolüsyon ve sigmoid ile sınıf başına bir saliency map'e dönüştürülmektedir. Tespit modülü, makaledeki Algoritma 1 uyarınca bu harita üzerinden örtüşmeyen $K = 6$ adet ROI seçmektedir. MIL modülü, seçilen patch'leri ImageNet pretrained ResNet-18 (f_t) ile kodlamakta ve Ilse ve ark. (2018) tarafından önerilen gated attention mekanizmasıyla birleştirmektedir.

Loss fonksiyonu, her iki dalın çıktısı için ayrı BCE terimleri ve saliency map üzerinde bir regularization teriminden oluşmaktadır: $L = \sum_c [BCE(y_c, \hat{y}_{loc,c}) + BCE(y_c, \hat{y}_{mil,c})] + \lambda L_{reg}$. Çıkarımda iki dalın ortalaması alınmaktadır.

Tespit modülü türevlenebilir olmadığından MIL loss'unun gradyanı f_d 'ye ulaşmamakta, iki dal yalnızca ortak pooling fonksiyonu üzerinden bağlanmaktadır. Bu davranış uygulamada ayrı bir testle doğrulanmıştır.

3.2 ROI seçimi (Algoritma 1)


Tespit modülü, saliency map üzerinden birbiriyle önemli ölçüde örtüşmeyen K adet bölge seçmektedir. Makaledeki algoritma açgözlü çalışmaktadır: harita önce sınıf başına min-max normalize edilir ve sınıflar toplanır; ardından K kez, patch boyutuna karşılık gelen pencere içinde toplamı en yüksek konum seçilir ve seçilen bölge haritadan silinerek bir

sonraki seçimin aynı yere düşmesi engellenir. Seçilen konumlar saliency map ölçeğinden girdi ölçeğine taşınır ve patch'ler orijinal çözünürlükten kesilir; böylece MIL modülü aşağı örneklenmemiş piksellerle çalışır.

Uygulamada tek sapma silme değerindedir. Makale ve yayınlanan kod seçilen bölgeyi sıfırlar. Min-max normalizasyon sonrası arka plan zaten tam sıfır olduğundan, tepeler sıfırlandığında harita her yerde sıfıra eşitlenmekte ve argmax sürekli aynı konumu (0,0) döndürmektedir; bu durumda aynı patch K kez MIL modülüne girmektedir. Silme değeri -1 olarak değiştirilmiştir. Harita pozitif değerler içerdiği sürece davranış sıfır ile aynı, dejenere durumda ise doğrudur. Bu davranış, düz bir saliency map ile ayrıca test edilmiştir.

3.3 Ön işleme

Makale ön işleme adımlarını Wu ve ark. (2019) çalışmasına atıfla geçmekte ve augmentation listesi vermemektedir. Bu nedenle adımlar yazarların yayınladığı uygulamadan alınmıştır: meme dokusunun çevresindeki arka plan crop edilmekte, sağ memeler yatay çevrilerek tüm görüntüler aynı yöne bakacak şekilde normalize edilmekte ve görüntü başına z-score uygulanmaktadır. Girdi çözünürlüğü 2304×1280 , patch boyutu 256×256 olarak korunmuştur.




Şekil 2. Crop, yön normalizasyonu ve z-score sonrası örnek görüntüler.

3.4 Augmentation

Makale augmentation listesi vermemekte, yayınlanan uygulamada ise tek bir augmentation bulunmaktadır: crop penceresinin merkezine ve boyutuna eklenen rastgele gürültü. Bu tercih mamografiye özgüdür. Yatay çevirme kullanılamaz, çünkü ön işleme adımı tüm görüntüler aynı yöne bakacak şekilde normalize edilmiştir; çevirme bu bilgiyi yok eder. Döndürme ve ölçek dönüşümleri de rutin olarak uygulanmaz, zira meme pozisyonu çekim protokolü tarafından standartlaştırılmıştır.

Bu çalışmada aynı tercih korunmuştur: eğitimde pencere merkezi en fazla 100 piksel kaydırılır ve pencere boyutu en fazla 100 piksel değiştirilerek hedef boyuta yeniden ölçeklenir; doğrulama ve test kümelerinde gürültü uygulanmaz. Boyut gürültüsünün tam semantiği yayınlanan koddan çıkarılamadığı için yaklaşık %4 büyüklüğünde bir zoom değişimi olarak uygulanmıştır.




Şekil 3. Aynı görüntünün gürültüsüz hali (doğrulama/test) ve eğitimde üretilen üç farklı crop penceresi.

Veri ölçeğinin makaledekinden yaklaşık 120 kat küçük olması, bu minimal augmentation tercihinin bu ölçekte de doğru olup olmadığı sorusunu doğurmaktadır. Soru açık bırakılmamış, ek bir ablasyon olarak ölçülmüştür (Bölüm 5.1, gmic_augment): mamografiye uygun daha geniş bir augmentation seti eklendiğinde sonuç değişmemiştir.

3.5 Hiperparametre araması

Makale dört parametre üzerinde logaritmik ölçekte rastgele arama yapmakta ve 100 model eğitmektedir. Mevcut hesaplama bütçesi bunu karşılamadığından, aynı aralıklarda 12 koşu ve koşu başına 15 epoch ile daraltılmış bir arama yürütülmüştür. Seçim ölçütü makaledekiyle aynı tutulmuş, doğrulama kümesi malign AUC değeri kullanılmıştır. Seçilen konfigürasyon tüm ablasyonlarda sabitlenmiştir: $\eta = 6,148e-05$, $\lambda = 6,025e-05$, $\beta = 4,510$, $t = 0,1535$.



Şekil 4. Her hiperparametreye karşı doğrulama kümesi malign AUC değeri. Halka ile işaretlenen nokta seçilen konfigürasyondur.

Aramada bir kenar etkisi gözlenmiştir. Kazanan β değeri 4,51 olup makaledeki aralığın üst sınırına (4,95) oldukça yakındır; seçilen öğrenme oranı da örneklenen en büyük değerlere yakındır. On iki çekiliş ile dört boyutlu arama uzayının üst bölgesi yeterince taranamamıştır. Aralıklar makaleden olduğu gibi alındığı için genişletilmemiş, bu durum bir sınırlama olarak kaydedilmiştir.

4. Makale → CMMD2022 Uyarlamaları

Aşağıdaki tablo yöntemin her adımını makaledeki tanımla karşılaştırmakta, farklılık bulunan yerlerde yapılan uyarlamayı ve gerekçesini vermektedir. Tablonun ilk dokuz satırı değiştirilmeden uygulanan bileşenleri, kalan satırlar veri setinin dayattığı uyarlamaları göstermektedir. Uyarlamaların hiçbiri mimariyi değiştirmemekte, yalnızca veri setinin makaledekinden ayrıldığı noktalara karşılık gelmektedir.

konu	makale	CMMD2022	uyarlama ve gerekçe
Lokalizasyon ağı f_d	ResNet-22, sıfırdan eğitilir	Aynı	Birebir uygulandı.
Saliency map	1×1 conv + sigmoid, sınıf başına bir harita	Aynı	Birebir uygulandı.
Pooling f_agg	top-t% ortalaması	Aynı	Birebir uygulandı.
Patch ağı f_t	ResNet-18, ImageNet pretrained	Aynı	Birebir uygulandı. ResNet-22 için yayınlanmış ImageNet ağırlığı bulunmadığından f_d tohumlanamaz; bu soru gmic_ft_scratch ablasyonu ile ters yönden ölçüldü.
MIL birleştirme	Gated attention (Ilse ve ark. 2018)	Aynı	Birebir uygulandı.
Gradyan akışı	Tespit modülü türevlenebilir değil; MIL loss f_d'ye akmaz	Aynı	Birebir uygulandı, ayrı bir testle doğrulandı.
Çıkarım	$(\hat{y}_{loc} + \hat{y}_{mil}) / 2$	Aynı	Birebir uygulandı.
Meme tahmini	CC ve MLO görüntülerinin ortalaması	Aynı	Birebir uygulandı.
Augmentation	Yalnızca crop penceresi konum ve boyut gürültüsü	Aynı	Birebir uygulandı. Bu ölçekte yeterli olup olmadığı gmic_augment ablasyonu ile ayrıca ölçüldü.
Ölçek	229.426 tetkik, yaklaşık 1 milyon görüntü	1.771 hasta, 3.734 görüntü	Hiperparametre araması 100 model yerine 12 koşu; sabit 40 epoch yerine early stopping (patience 10). Aranılan aralıklar değiştirilmedi.
Etiket uzayı	$y \in \{0,1\}^2$; negatif (sağlıklı) tetkikler mevcut	Her meme ya benign ya malign; sağlıklı meme yok	Mimari korundu: iki sigmoid başlık, iki saliency map, iki BCE terimi. Görev malign-benign ayırımına dönüştü.
Dengeli örnekleme	Her iterasyonda pozitifler + eşit sayıda rastgele negatif	Negatif sınıf yok; dengesizlik D2 alt kümesinden geliyor	WeightedRandomSampler, ağırlıklar sınıf × alt küme üzerinden. Yalnız sınıfa göre ağırlıkla mak benign'i çekerken D1'i de yukarı çekiyor ve alt küme dağılımını bozuyordu.
Girdi çözünürlüğü	2944×1920, native çözünürlük	2294×1914, istisnasız tüm görüntüler aynı	Native çözünürlük korundu: 2304×1280 (p99 boyutu, 32'nin katı). Patch boyutu 256 sabit. Bellek yeterli olduğundan kademeli düşürmeye gerek kalmadı.
Normalizasyon	Görüntü başına z-score, istatistikler pencerenin tamamından	Pencerenin yaklaşık yarısı dolgu; dolgu oranı görüntüden görüntüye değişiyor	İstatistikler meme maskesi içinden alındı. Pencere geneli normalizasyon, doku ortalamasını doluluk oranına bağlıyordu (ölçülen korelasyon 0,85).
ROI seçimi	Algoritma 1; seçilen bölge haritadan sıfırlanır	Min-max normalizasyon sonrası arka plan zaten tam sıfır	Silme değeri -1 yapıldı. Sıfırlama ile harita her yerde sıfıra eşitleniyor, argmax aynı konumu döndürüyor ve aynı patch K kez MIL modülüne giriyordu.
Loss	$L = \Sigma[BCE + BCE] + \lambda \cdot L_{reg}$	$\beta < 1$ iken $ A ^\beta$ türevi $A \rightarrow 0$ 'da ıraksıyor; AMP altında sigmoid tam sıfıra underflow ediyor	L_{reg} 'e alt sınır eklendi (clamp_min). Loss değerine etkisi 678 birim üzerinden 0,0016.
Test kümesi	Ayrı 14.148 tetkiklik test seti	Tek havuz	Hasta seviyesinde stratified split %70/15/15; katman etiketi sınıf × alt küme. Aynı hastanın tüm görüntüleri tek bölünmede tutuldu.
Değerlendirme kohortu	Tek kohort	Yaş 0,682, D1/D2 göstergesi 0,776, ikisi birlikte 0,847 AUC veriyor	Birincil kohort D1 seçildi. D2'de 115 memenin 113'ü malign olduğundan orada AUC pratik olarak tanımsız.

konu	makale	CMMD2022	uyarlama ve gerekçe
Etiketsiz meme	Yok; tüm tetkikler etiketli	729 görüntülenmiş meme etiketsiz (kontralateral)	Eğitime alınmadı. Biyopsi doğrulaması olmadan negatif varsayılmaz.
Veri bütünlüğü	—	Dört hastada yinelenen piksel ve çelişen etiket (arşiv uyarısı md5 ile doğrulandı)	Dört hasta da çıkarıldı; liste ozet/haric_hastalar.json dosyasında.
Lokalizasyon metriği	Piksel maskeleriyle sürekli F1 / precision / recall	Piksel düzeyi lezyon maskesi yok	Nicel metrik üretilmedi. Yerine makaledeki Şekil 4'ün nitel karşılığı (Bölüm 7) ve saliency aktivasyonunun meme maskesi içinde kalma oranı raporlandı.
Moleküler alt tip	Yok	749 hasta için mevcut	Eğitimde kullanılmadı; yalnızca vaka görsellerinde bağlam olarak verildi.
Ek ablasyon	Yok	Veri 120 kat küçük, overfitting baskısı farklı	gmic_augment eklendi: rotasyon $\pm 15^\circ$, parlaklık/kontrast $\pm 0,15$, hafif affine. Ana tarif değiştirilmedi, ayrı koşu olarak ölçüldü.


5. Sonuçlar

Değerlendirme test kümesinin D1 kohortu üzerinde yapılmıştır: 165 meme, bunların 85 tanesi malign, 80 tanesi benigndir. Güven aralıkları sınıfa göre stratified bootstrap ile 2.000 tekrar üzerinden hesaplanmıştır. Model karşılaştırmalarında DeLong testi kullanılmıştır; aynı memeler üzerinde üretilen tahminler korelasyonlu olduğundan eşleşmiş bir test gereklidir.

5.1 Ana karşılaştırma

model	tür	AUC	CI alt	CI üst	Δ baseline	p (baseline)	Δ gmic	p (gmic)
ensemble_top3	türetilmiş	0,791	0,720	0,858	0,137	0,000	0,054	0,029
gmic_hp2	eğitilmiş	0,782	0,708	0,847	0,128	0,001	0,045	0,247
gmic_lowres	eğitilmiş	0,759	0,687	0,826	0,105	0,009	0,022	0,582
gmic_noattn	eğitilmiş	0,751	0,676	0,820	0,098	0,028	0,014	0,730
gmic_mil	türetilmiş	0,741	0,667	0,813	0,087	0,049	0,004	0,855
gmic_hp3	eğitilmiş	0,740	0,663	0,813	0,086	0,049	0,003	0,944
gmic	eğitilmiş	0,737	0,660	0,810	0,083	0,024	0,000	1,000
gmic_augment	eğitilmiş	0,726	0,647	0,804	0,073	0,091	-0,011	0,773
gmic_random	eğitilmiş	0,716	0,636	0,792	0,062	0,054	-0,021	0,565
gmic_loc_random	türetilmiş	0,704	0,622	0,782	0,050	0,128	-0,033	0,294
gmic_ft_scratch	eğitilmiş	0,702	0,620	0,780	0,048	0,137	-0,035	0,368
gmic_loc	türetilmiş	0,657	0,572	0,739	0,003	0,926	-0,080	0,006
resnet22_baseline	eğitilmiş	0,654	0,573	0,736	0,000	1,000	-0,083	0,024

Δ sütunları AUC farkını, p sütunları DeLong testinin iki yönlü p değerini göstermektedir. Türetilmiş olarak işaretlenen modeller ayrıca eğitilmemiş, mevcut çıktılarından hesaplanmıştır: gmic_loc tam modelin global dalı, gmic_mil MIL dalı, gmic_loc_random tam modelin global dalı ile rastgele patch varyantının MIL dalının ortalaması, ensemble_top3 ise aramadan çıkan ilk üç konfigürasyonun ortalamasıdır.



Şekil 5. Modellerin AUC değerleri ve %95 bootstrap güven aralıkları. Noktalı dikey çizgi baseline seviyesini göstermektedir.

5.2 Makale sonuçlarıyla karşılaştırma

Aşağıdaki tablo, makalenin Tablo 1'inde bildirilen malign AUC değerleri ile bu çalışmada D1 kohortunda elde edilen değerleri yan yana vermektedir. Mutlak değerler karşılaştırılabilir değildir; anlamlı olan varyantlar arası sıralamadır.

varyant	makale (malign AUC)	bu çalışma (D1)	fark
ResNet-22 (baseline)	0,827	0,654	-0,173
GMIC-loc	0,885	0,657	-0,228
GMIC-mil	0,878	0,741	-0,137
GMIC-noattn	0,823	0,751	-0,072
GMIC-random	0,757	0,716	-0,041
GMIC-loc-random	0,889	0,704	-0,185
GMIC (tam model)	0,900	0,737	-0,163

Makale sütunu Shen ve ark. (2019) Tablo 1'den alınmıştır. Bu çalışmada GMIC-loc, GMIC-mil ve GMIC-loc-random varyantları ayrıca eğitilmemiş, tam modelin ve rastgele patch varyantının çıktılarından türetilmiştir.

Baseline ile tam model arasındaki fark her iki çalışmada da aynı yöndedir ve benzer büyüklüktedir (makalede 0,073, burada 0,083). GMIC-random varyantının tam modelin altında kalması da ortaktır. Buna karşılık GMIC-loc varyantı makalede baseline'ı açıklıkla aşarken bu çalışmada baseline seviyesinde kalmakta, GMIC-noattn ise makalede baseline seviyesine düşerken burada tam modelden ayırt edilememektedir.

5.3 Doğrulanen bulgular

GMIC, baseline modelini 0,737 karşısında 0,654 ile aşmaktadır; fark 0,083 olup $p = 0,024$ düzeyinde anlamlıdır. Bu karşılaştırma çalışma tasarımında önceden belirlendiğinden çoklu karşılaştırma düzeltmesine tabi değildir.

İlk üç konfigürasyonun ensemble'ı 0,791 [0,720–0,858] ile en yüksek sonucu vermekte ve tek başına tam modeli de anlamlı olarak aşmaktadır ($p = 0,029$). Bu bulgu, arama sonuçlarında ilk üç konfigürasyonun birbirinden ayırt edilememesiyle tutarlıdır.

Global dalın tek başına yetersiz kaldığı görülmektedir. gmic_loc varyantı 0,657 değerinde olup baseline'dan farksızdır ($p = 0,93$) ve tam modelden anlamlı olarak düşüktür ($p = 0,006$). Makalede GMIC-loc varyantı 0,885 ile baseline'ı (0,827) açıklıkla aşmaktaydı. Bu veri setinde performansı taşıyan bileşen MIL dalıdır; tam model ile gmic_mil arasında anlamlı fark bulunmamaktadır ($p = 0,85$). Makaleden ayrılan en belirgin bulgu budur.

5.4 Ölçülemeyen farklar

Ablasyon varyantlarının hiçbirisi tam modelden istatistiksel olarak ayırt edilememektedir. Attention mekanizmasının devre dışı bırakıldığı varyant için $p = 0,73$, yarı çözünürlük varyantı için $p = 0,58$, rastgele patch varyantı için $p = 0,57$, ImageNet pretrained ağırlıkları olmadan eğitilen varyant için $p = 0,37$ elde edilmiştir.

Bu sonucun doğru yorumu, söz konusu bileşenlerin katkısız olduğu değil, katkılarının mevcut örneklem büyüklüğünde ölçülemediğidir. Ortalama güven aralığı genişliği 0,152 iken makalede bildirilen ablasyon etkileri 0,02 ile 0,08 aralığındadır; aranan etki büyüklüğü, ölçüm belirsizliğinin altında kalmaktadır.


Baseline'a karşı toplam 12 karşılaştırma yapılmıştır. $\alpha = 0,05$ düzeyinde tesadüfen bir yanlış pozitif gözlenmesi beklenir. Bonferroni düzeltmesi uygulandığında (eşik $0,05/12 = 0,0042$) yalnızca ensemble_top3, gmic_hp2 varyantları anlamlı kalmaktadır. Keşifsel nitelikteki ablasyon karşılaştırmaları bu eşikle değerlendirilmelidir; önceden belirlenmiş birincil hipotez bu düzeltmenin kapsamı dışındadır.

5.5 Alt gruplar


model	kırılım	değer	n	n malign	ensemble_top3	gmic	gmic_loc	gmic_mil	resnet22_baseline
	abnormality	both	65,000	59,000	0,887	0,816	0,542	0,898	0,729
	abnormality	calcification	38,000	29,000	0,739	0,759	0,636	0,793	0,713
	abnormality	mass	177,000	110,000	0,775	0,710	0,657	0,704	0,635
	alt küme	D1	165,000	85,000	0,791	0,737	0,657	0,741	0,654
	alt küme	D2	115,000	113,000	0,770	0,819	0,845	0,726	0,832
	yaş	45-55	83,000	63,000	0,897	0,817	0,620	0,883	0,686
	yaş	<45	124,000	71,000	0,713	0,637	0,613	0,629	0,604
	yaş	>55	73,000	64,000	0,738	0,723	0,444	0,783	0,540

Alt grupların büyük kısmı tek taraflı bir sınıf dağılımına sahiptir. D2 kohortunda ve abnormality değeri "both" olan kırılımda negatif örnek sayısı tek haneli olduğundan bu satırlardaki AUC değerleri yorumlanamaz. İstatistiksel olarak değerlendirilebilir tek alt grup "mass" kırılımıdır.

6. Eğitim Davranışı




Şekil 6. GMIC eğitim eğrileri: loss bileşenleri, AUC gelişimi, attention entropisi ve saliency aktivasyonu.




Şekil 7. ResNet-22 baseline eğitim eğrileri.

7. Vaka Görselleri


Aşağıdaki görseller makaledeki Şekil 4'ün karşılığıdır. Her vakada sırasıyla ön işlenmiş girdi, benign ve malign saliency map'leri (sabit 0–1 ölçeğinde), Algoritma 1 tarafından seçilen 6 ROI ve attention ağırlığına göre sıralanmış patch'ler yer almaktadır. CMMD2022 veri setinde piksel düzeyinde lezyon maskesi bulunmadığından makaledeki nicel lokalizasyon metrikleri hesaplanamamış, yerine bu nitel değerlendirme sunulmuştur.




Şekil 8. D2-0550_R — Malignant, mass, 46 yaş, D2 alt kümesi.




Şekil 9. D2-0094_R — Malignant, calcification, 47 yaş, D2 alt kümesi.




Şekil 10. D1-0365_R — Malignant, both, 78 yaş, D1 alt kümesi.



Şekil 11. D1-0894_R — Benign, mass, 37 yaş, D1 alt kümesi.



Şekil 12. D1-0033_R — Benign, calcification, 57 yaş, D1 alt kümesi.



Şekil 13. D1-0242_R — Benign, both, 58 yaş, D1 alt kümesi.

8. Sonuç ve Sınırlamalar

GMIC'in temel iddiası, yani saliency map üzerinden seçilen yüksek çözünürlüklü patch'lerin MIL ile birleştirilmesinin aynı backbone'a sahip bir sınıflandırıcıya göre daha iyi sonuç verdiği önermesi, bu veri setinde de geçerlidir ve istatistiksel olarak desteklenmektedir. Ancak kazancın mimarının hangi bileşeninden geldiği ayrıştırılamamıştır. Makalede her iki dal da baseline'i aşarken, bu çalışmada global dal baseline seviyesinde kalmakta, kazanç MIL dalından gelmektedir.

Çalışmanın sınırlamaları aşağıda sıralanmıştır.

- Test kohortu 165 meme ile sınırlıdır ve güven aralıkları yaklaşık 0,15 genişliğindedir. Ablasyon farklarını ölçecek istatistiksel güç bulunmamaktadır.
- Veri seti makaledekinden yaklaşık 120 kat küçüktür; mutlak AUC değerleri karşılaştırılabilir nitelikte değildir.
- Hiperparametre araması sırasında batch boyutu ayarı değişmiştir (4'ten 16'ya). Efektif batch boyutu sabit kalmakla birlikte BatchNorm istatistikleri batch boyutuna bağlıdır; koşulların bir kısmı farklı ayar altında seçilmiştir.
- Alt grup analizleri, negatif örnek sayıları yetersiz olduğundan "mass" kırılımı dışında yorumlanamaz.
- Rastgele patch varyantının RNG durumu checkpoint'e yazılmadığından, eğitim yarıda kesilip devam ettirildiğinde patch dizisi baştan başlamaktadır.

Kaynaklar

1. Shen Y, Wu N, Phang J, Park J, Kim G, Moy L, Cho K, Geras KJ. Globally-Aware Multiple Instance Classifier for Breast Cancer Screening. In: Suk H-I ve ark. (Ed.) MLMI 2019, LNCS 11861, s. 18–26. Springer, 2019. DOI: 10.1007/978-3-030-32692-0_3.
2. Wu N, Phang J, Park J, ve ark. Deep Neural Networks Improve Radiologists' Performance in Breast Cancer Screening. IEEE Transactions on Medical Imaging 2020;39(4):1184–1194. DOI: 10.1109/TMI.2019.2945514. Uygulama: github.com/nyukat/GMIC ve github.com/nyukat/breast_cancer_classifier.

3. Ilse M, Tomczak JM, Welling M. Attention-based Deep Multiple Instance Learning. ICML 2018. arXiv:1802.04712.
4. Cui C, Li L, Cai H, Fan Z, Zhang L, Dan T, Li J, Wang J. The Chinese Mammography Database (CMMD): An Online Mammography Database with Biopsy Confirmed Types for Machine Diagnosis of Breast. The Cancer Imaging Archive, 2021. DOI: 10.7937/tcia.eqde-4b16.
5. Cai H, Wang J, Dan T, Li J, Fan Z, Yi W, Cui C, Jiang X, Li L. An Online Mammography Database with Biopsy Confirmed Types. Scientific Data 2023;10:123. DOI: 10.1038/s41597-023-02025-1.
6. DeLong ER, DeLong DM, Clarke-Pearson DL. Comparing the Areas under Two or More Correlated ROC Curves: A Nonparametric Approach. Biometrics 1988;44(3):837–845.
7. Sun X, Xu W. Fast Implementation of DeLong's Algorithm for Comparing the Areas Under Correlated ROC Curves. IEEE Signal Processing Letters 2014;21(11):1389–1393.