

# Gerçek Zamanlı Meme Ultrason Lezyon Segmentasyonu

Üç mimarinin kalite ve hız karşılaştırması — RTMDet-Ins-tiny, SegFormer-B0, YOLOv11n-Seg · her mimari, başlangıç değeri değiştirilerek üç kez eğitildi

Özet. Üç mimari 256×256 girdide, aynı veri bölünmesi ve aynı değerlendirme protokolüyle, her biri farklı rastgele başlangıçla üç kez eğitildi — toplam dokuz koşu. Sonuç: RTMDet-Ins ile SegFormer-B0 arasında ayırt edilebilir bir kalite farkı yok. SegFormer-B0, YOLOv11n-Seg'e göre istatistiksel olarak anlamlı bir üstünlük gösteriyor; RTMDet-Ins'in ortalama Dice değeri de YOLOv11n-Seg'den yüksek olmakla birlikte bu fark anlamlı bulunmadı. Buna karşılık modeller nerede iyi oldukları bakımından belirgin şekilde ayrılıyor: küçük lezyonlarda SegFormer, büyük lezyonlarda RTMDet önde. Hız sıralaması ise çalışma ortamına göre tümüyle değişiyor.

## 1. Amaç, veri ve protokol

Hedef, meme ultrasonunda lezyonun canlı görüntü akışı üzerinde segmentasyonu. İki soru var: hangi mimari daha iyi segmentliyor ve hangisi gerçek zamanlı çalışabiliyor. Üç mimari seçildi — biri semantic (SegFormer-B0), ikisi instance segmentation (RTMDet-Ins-tiny, YOLOv11n-Seg). Karşılaştırmanın mimariyi ölçmesi için veri bölünmesi, girdi hazırlığı, augmentasyon zinciri, girdi boyutu ve değerlendirme protokolü üçünde de sabit tutuldu.

Görev tanımları aynı olmadığı için instance modellerinin çıktıları tek bir ikili lezyon maskesine indirgendi: her piksel, kendisini kapsayan örneklerin en yüksek skorunu alıyor, yani eşikleme skoru eşik'in üstündeki örneklerin birleşimine karşılık geliyor. Üç modelin çıktısı da bu biçimde orijinal çözünürlükte Dice üzerinden karşılaştırıldı. Çalışmanın sorusu lezyonların ayrı ayrı sayılması değil sınırlarının doğru çizilmesi olduğundan indirgeme bilgi kaybına yol açmıyor.

Veri kaynağı BUSI (Breast Ultrasound Images): 780 görüntü, benign 437 / malignant 210 / normal 133. Veri setinde 115 teyitli kopya çifti var; 179 görüntü (%23) kopya gruplarının içinde ve 11'i "aynı görüntü, çelişkili maske". Tespit iki aşamalı: önce algısal karma (dHash, 64 bit, Hamming uzaklığı  $\leq 6$ ) ile aday çiftler üretildi, sonra her aday 128×128'e küçültülüp z-normalize edilerek Pearson korelasyonu ve maske IoU'su ile teyit edildi; korelasyonu 0.95'in üzerinde olan çiftler kopya sayıldı. Rastgele bölünmede bu görüntüler eğitim ve teste dağılsaydı model ezberlediği kareyi tekrar görür, Dice yapay olarak şişerdi. Çelişkili çiftlerde deterministik bir kuralla tek temsilci bırakıldı (780 görüntüden 769'a) ve bölme kopya grubu düzeyinde yapıldı: eğitim 538, validation 116, test 115; val ve test tamamen kopyasız.

### 1.1 Ölçüm protokolü

Ortak metrik orijinal çözünürlükte Dice; küçültülmüş uzayda ölçmek semantic modele yapay avantaj verirdi. Lezyonsuz normal görüntüler veri setinde tutuldu — canlı akışta karelerin çoğunda lezyon yok ve boş maskeler yanlış pozitif baskılamayı öğretiyor. Bu görüntülerde gerçek maske ve tahmin birlikte boşsa Dice 1 sayılıyor; lezyonlu ve boş kırımları ayrı veriliyor.

Karar eşiği validation'da seçilip teste sabit uygulandı, test üzerinde eşik taraması yapılmadı. Seçim ölçütü tüm görüntüler üzerinden Dice; yalnızca lezyonlu görüntülere bakan bir ölçüt, boş görüntülerde yanlış pozitif üreten düşük eşikleri ödüllendiriyor.


## 1.2 Neden her mimari üç kez eğitildi

İlk turda her mimari bir kez eğitilmiş ve sonuç "SegFormer en iyi" çıkmıştı. Rastgele başlangıç değiştirilerek yapılan tekrarlar da tek bir mimarinin kendi koşulları arasındaki fark, mimariler arasında ölçtüğümüz farktan büyük çıktı; bu da ilk turun sıralamasını geçersiz kılıyor. Aşağıdaki bütün sayılar üç koşunun dağılımıyla veriliyor.

## 2. Kalite sonuçları

| Mimari       | Test Dice (lezyonlu) | Test Dice (tüm) | Koşular arası aralık |
|--------------|----------------------|-----------------|----------------------|
| RTMDet-Ins   | 0.7212 ± 0.0160      | 0.7615 ± 0.0089 | 0.0314               |
| SegFormer-B0 | 0.7335 ± 0.0083      | 0.7601 ± 0.0156 | 0.0165               |
| YOLOv11n-Seg | 0.6986 ± 0.0127      | 0.7281 ± 0.0096 | 0.0231               |

Test seti, 115 görüntü (96 lezyonlu, 19 boş). Her hücre üç koşunun ortalaması ± standart sapması.




Şekil 1. Dokuz koşunun test Dice değerleri. Noktalar tek koşular, yatay çizgi ortalama, bant ±1 standart sapma. RTMDet ve SegFormer bantları büyük ölçüde üst üste biniyor — aralarındaki fark koşudan koşuya değişen gürültünün içinde kalıyor.

## 2.1 Modeller ayrışıyor mu

Her görüntü için üç koşunun Dice ortalaması alınıp mimariler görüntü bazında eşleştirilerek karşılaştırıldı (bootstrap %95 güven aralığı ve Wilcoxon işaretli sıra testi, n=96).

| A            | B            | Fark   | %95 GA            | Wilcoxon p | A iyi / B iyi | Ayrışıyor |
|--------------|--------------|--------|-------------------|------------|---------------|-----------|
| RTMDet-Ins   | SegFormer-B0 | -0.012 | -0.053 ... +0.026 | 0.846      | 46 / 45       | hayir     |
| RTMDet-Ins   | YOLOv11n-Seg | 0.023  | -0.020 ... +0.063 | 0.058      | 56 / 35       | hayir     |
| SegFormer-B0 | YOLOv11n-Seg | 0.035  | +0.004 ... +0.067 | 0.003      | 55 / 34       | EVET      |



Şekil 2. Eşleştirilmiş fark ve %95 güven aralığı. Yalnızca SegFormer–YOLO aralığı sıfırı dışarıda bırakıyor.

Sonuç belirli bir başlangıç değerine bağlı mı diye, koşuların dokuz çapraz eşleşmesi de ayrı ayrı test edildi:

| A            | B            | Fark (min / ort / maks)  | Tek başına anlamlı | İşaret hep aynı |
|--------------|--------------|--------------------------|--------------------|-----------------|
| RTMDet-Ins   | SegFormer-B0 | -0.038 / -0.012 / +0.010 | 0/9                | hayir           |
| RTMDet-Ins   | YOLOv11n-Seg | -0.010 / +0.023 / +0.045 | 0/9                | hayir           |
| SegFormer-B0 | YOLOv11n-Seg | +0.012 / +0.035 / +0.051 | 3/9                | EVET            |

Ne söylenebilir: SegFormer-B0, YOLOv11n-Seg'i lezyonlu Dice'ta geçiyor (+0.035,  $p=0.003$ ). Dokuz çapraz koşu eşleşmesinin dokuzunda da fark aynı yönde — bu sonuç belirli bir başlangıç değerine bağlı değil.

Ne söylenemez: RTMDet-Ins ile SegFormer-B0 arasında fark yok ( $p=0.85$ , güven aralığı sıfırı kapsıyor, 96 görüntünün 46'sında biri 45'inde diğeri önde). Bu iki mimari eldeki veriyle ayırt edilemiyor.


RTMDet–YOLO farkı (+0.023) SegFormer–YOLO farkından (+0.035) çok geride olmadığı hâlde anlamlı çıkmıyor ( $p=0.058$ ). Sebep RTMDet'in koşular arası değişkenliğinin ( $\pm 0.016$ ) SegFormer'inkinin ( $\pm 0.008$ ) iki katı olması. Model seçiminde ortalama performans kadar eğitim kararlılığı da bir ölçüt; SegFormer'ın encoder'ı ImageNet ön eğitilmiş olduğu için başlangıç noktası sabit, RTMDet'in tespit başı sıfırdan öğreniyor.

## 2.2 Hangi model nerede iyi

Toplam ortalamalar ayırt edilemiyor olsa da, lezyon boyutuna göre kıldığımızda tablo değişiyor.

| Lezyon çapı (px) | RTMDet-Ins    | SegFormer-B0  | YOLOv11n-Seg  |
|------------------|---------------|---------------|---------------|
| <80 (n=16)       | 0.648 ± 0.027 | 0.776 ± 0.009 | 0.707 ± 0.049 |
| 80-140 (n=28)    | 0.799 ± 0.014 | 0.832 ± 0.002 | 0.753 ± 0.014 |
| 140-220 (n=29)   | 0.664 ± 0.007 | 0.655 ± 0.014 | 0.671 ± 0.014 |
| >220 (n=23)      | 0.750 ± 0.046 | 0.683 ± 0.020 | 0.662 ± 0.033 |

Test Dice, üç koşunun ortalaması ± standart sapması. Kova sınırları lezyonun eşdeğer çapına göre.




Şekil 3. Lezyon boyutuna göre test Dice. İki bağımsız örüntü var: orta boy lezyonlardaki düşüş üç mimaride de aynı yerde, buna karşılık uç kovalarda mimariler ters yönde ayrışıyor.

Bu veri setindeki sonuçlar, küçük lezyonlarda SegFormer-B0'ın, büyük lezyonlarda ise RTMDet-Ins'in daha yüksek Dice değeri elde etme eğiliminde olduğunu gösteriyor. 80 pikselin altındaki lezyonlarda SegFormer RTMDet'i 0.13 geçiyor (0.776 / 0.648); 220 pikselin üstünde RTMDet SegFormer'ı 0.067 geçiyor (0.750 / 0.683). Kova başına görüntü sayısı 16–29 arasında olduğundan bunlar gözlenen eğilimler, kesin genellemeler değil. SegFormer'in stride 4'teki yoğun decoder'ı ile RTMDet'in bölge tabanlı maske başı düşünüldüğünde beklenen bir davranış. İki modelin toplam ortalamalarının neden ayırt edilemediğini de açıklıyor: farklı yerlerde iyiler ve ortalamada birbirlerini götürüyorlar.

İki yönün kanıt gücü eşit değil. Küçük lezyonlardaki fark koşular arası saçılmanın çok üstünde (0.13'e karşı ±0.027 ve ±0.009). Büyük lezyonlardaki ters yöndeki fark ise RTMDet'in bu kovadaki saçılması yüksek olduğu için (±0.046) daha zayıf.

140–220 piksel kovasındaki düşüş mimariden bağımsız: üç mimaride de aynı yerde ve birbirine çok yakın (0.655–0.671), dokuz koşunun hepsinde. Örüntü monotonik olmadığından — daha büyük lezyonlarda Dice tekrar yükseliyor — lezyon büyüklüğüyle açıklanmıyor. Bu kovadaki 29 görüntünün incelenmesi bu raporun kapsamı dışında bırakıldı.




Şekil 4. Sabit değerlendirme vakalarında üç modelin tahminleri (her mimarinin ilk koşusu). Boş maskeli normal görüntüler, boyut kovalarının her birinden birer örnek.

### 3. Hız

Üç model de aynı makinede ölçüldü (RTX 2060, batch=1). Ölçülen büyüklük kare başına uçtan uca süre: ön işleme, ileri geçiş ve maskeyi orijinal çözünürlüğe taşıma. Diskten görüntü okuma hariç, çünkü canlı akışta kare cihazdan gelir.

| Mimari       | Param (M) | PyTorch uçtan uca (ms) | FPS   | Çerçeve yükü | ONNX GPU (ms) | ONNX CPU (ms) | VRAM (MB) |
|--------------|-----------|------------------------|-------|--------------|---------------|---------------|-----------|
| SegFormer-B0 | 3.71      | 11.02                  | 90.70 | %23          | 4.23          | 19.47         | 63.00     |
| YOLOv11n-Seg | 2.84      | 13.65                  | 73.30 | %30          | 4.95          | 6.72          | 31.90     |
| RTMDet-Ins   | 5.62      | 23.27                  | 43.00 | %48          | 4.07          | 11.11         | 88.90     |


"Çerçeve yükü", uçtan uca sürenin saf ağ ileri geçişi dışında kalan kısmı. ONNX sütunları yalnızca ağ ileri geçişini ölçüyor; uç ağ da ONNX'e çevrilip aynı çalışma zamanında (onnxruntime) koşuldu, bağıl sapma üçünde de 1e-5'in altında.



Şekil 5. Kalite-hız dengesi üç farklı çalışma ortamında. Sıralama üç panelde üç farklı çıkıyor. Kesikli çizgi 30 FPS.

Ölçüm koşulları altında üç model de 30 FPS eşiğinin üzerinde; başka bir donanımda veya farklı bir görüntü alma hattında sonuç değişebilir. Sıralama ortama göre tersine dönüyor: PyTorch'ta RTMDet en yavaş (43 FPS), ancak gecikmesinin %48'i mmdet çerçevesinin kare başına Python yükü. Aynı çalışma zamanında ONNX olarak ölçüldüğünde en düşük süreyi RTMDet veriyor (4.07 ms), CPU'da ise YOLO açık ara önde (6.72 ms). "Şu model gerçek zamanlı çalışır" cümlesi, çalışma zamanı ve dağıtım yolu belirtilmeden anlamlı değil.

## 4. Eğitim davranışı



Şekil 6. Üstte eğitim (düz) ve validation (kesik) kaybı, altta validation kalitesi; her mimari için üç koşu. Kayıp fonksiyonları farklı olduğundan üst satırdaki üç panelin ölçekleri karşılaştırılabilir değil; alt satırda RTMDet ve SegFormer Dice, YOLO ise Ultralytics'in ürettiği maske mAP değerini gösteriyor. YOLO panelinde ölçek ilk 20 epoch dışına göre kuruldu, erken sıçramalar grafiği eziyordu.

Üç modelde de eğitim kaybı sona kadar düşerken validation kaybı 25.–40. epoch civarında düzleşiyor, buna rağmen validation kalitesi düşmüyor. Kayba bakarak erken durdurma yapılsaydı daha kötü bir checkpoint seçilirdi; bu yüzden seçim üç mimaride de orijinal çözünürlükteki Dice'a göre yapıldı. Seçilen epoch'lar 56–93 aralığına dağılıyor, yani 100 epoch'luk eğitim uzunluğu dar değil.

Kayıp fonksiyonu ve çerçeveye özgü validation metriği mimariler arasında farklı olduğundan bu grafikler modeller arası karşılaştırma için kullanılmadı; nihai karşılaştırma ortak Dice metriği üzerinden yapıldı.

Koşular arası saçılma bu eğrilerde de görünüyor ve model karşılaştırmasındaki tablo ile tutarlı: SegFormer'ın üç eğrisi neredeyse üst üste biniyor, RTMDet'in validation kaybı ise koşudan koşuya belirgin şekilde ayrışıyor.

## 5. Nasıl doğrulandı

- Colab'da eğitilen altı modelin validation sonucu yerel makinede yeniden hesaplandı; en büyük sapma 0.0001, yani çıkarım yolu ayrışmamış.
- Her koşuda tahmin maskesi  $\pm 2$  piksel kaydırılarak sistematik hizalama kayması arandı; dokuz koşuda da kazanç 0.003 eşiğinin altında.
- Eşik yalnızca validation'da seçildi; optimum tarama aralığının ucunda çıkarsa değerlendirme betiği hata veriyor.
- Hız ölçümünde kullanılan çıkarım fonksiyonunun kalite değerlendirmesindekiyle aynı çıktıyı ürettiği her modelde kontrol edildi (fark tam sıfır).

## 6. Sınırlılıklar

---

- Test seti küçük: 115 görüntü, 96'sı lezyonlu. Bu boyutta  $\pm 0.03$  mertebesindeki farklar güvenilir şekilde ayrıştırılamıyor; raporun sıralama değil ayırt edilebilirlik üzerine kurulmasının sebebi de bu.
- Tek veri kaynağı. BUSİ tek merkezli; başka cihaz ve popülasyona genelleme bu çalışmayla gösterilmiş değil.
- Mimari başına üç koşu azdır. Standart sapma tahminleri üç ölçümden geliyor, kendileri de gürültülü. Yön doğru, büyüklük kaba.
- Augmentasyon tam eşlenemedi: RTMDet ve SegFormer zincirindeki elastik deformasyon YOLO tarafında karşılıksız — Ultralytics'in sarmalayıcısı geometrik dönüşüme maske taşıyor. YOLO'nun aleyhine küçük bir fark yaratmış olabilir.
- 140–220 piksel kovalandığı düşüş açıklanmadı. Örneğin gerçek olduğu gösterildi, sebebi araştırılmadı.
- Girdi boyutunun ve augmentasyon şiddetinin etkisi bu çalışmada incelenmedi.

## 7. Sonuç

---

Kalite. RTMDet-Ins ile SegFormer-B0 bu veri setinde ayırt edilemiyor. SegFormer-B0'ın YOLOv11n-Seg'e üstünlüğü istatistiksel olarak anlamlı; RTMDet-Ins de YOLOv11n-Seg'den yüksek ortalama veriyor, ancak bu fark anlamlılık düzeyine ulaşmıyor. Tek bir "en iyi model" ilan etmek eldeki ölçümlerle desteklenmiyor.

Seçim ölçütü olarak kırım. Modeller ortalamada değil, lezyon boyutuna göre ayrışma eğilimi gösteriyor: küçük lezyonlarda SegFormer, büyük lezyonlarda RTMDet daha yüksek Dice veriyor. Uygulama senaryosuna bağlı olarak lezyon boyutu ve çalışma ortamı dikkate alınarak model seçimi yapılabilir.

Hız. Ölçüm koşulları altında üç model de gerçek zamanlı eşiğin üzerinde. Dağıtım PyTorch üzerinden olacaksa SegFormer-B0 en hızlısı (90.7 FPS); ONNX Runtime üzerinde üç model de birbirine yakın çıkarım sürelerine ulaşıyor ve en düşük ileri geçiş süresini RTMDet-Ins veriyor (4.07 ms, SegFormer 4.23 ms, YOLO 4.95 ms); CPU'da ise YOLOv11n-Seg belirgin şekilde önde.

Öneri. PyTorch dağıtımı ve karışık lezyon boyutları için SegFormer-B0: kalitede en kötü ihtimalle diğerleriyle aynı düzeyde, küçük lezyonlarda belirgin şekilde önde, koşullar arası en kararlı ve PyTorch üzerinde en hızlı model.

Sonraki aşama. Farklı girdi boyutlarının ve augmentasyon şiddetlerinin model performansı üzerindeki etkisinin incelenmesi ve 140–220 piksel kovalandığı düşüşün kaynağının araştırılması planlanmaktadır.